数字图像处理课程实习

综合实验报告

图像增强、几何校正、图像压缩

从传统算法到机器学习方法

姓名　韩勋同

学号　2025312132086

实验数据　SIED Canon 1000 张、GeoCorrection 200 张、Kodak 24 张

报告日期　2026 年 10 月 25 日

代码版本　`beebb345`，完整版本号见复现部分

最终 1000 张平均结果

PSNR 为 26.707356 dB，SSIM 为 0.843515758，LPIPS 为 0.324355896。

PSNR 比本轮基线提高 0.152867 dB。SSIM 略有下降。留出测试的两项主指标下降。

本报告记录三个项目实际完成的实验。图像增强采用最新的 1000 张完整评价。几何校正和压缩采用已保存的实验。原始数据、公开模型、自训权重和缺失资料分别说明。

目录

报告说明 1

第一部分 项目一极暗图像增强 2

1 实验任务和完成范围 2

2 数据读取和评价方法 2

3 算法设计和训练设置 4

4 模型选择和实验结果 6

5 可视化比较 9

6 速度、资源和验证 16

7 代码、模型权重和复现步骤 16

8 项目一结论和后续工作 20

第二部分 项目二几何校正 21

9 任务、数据和方法 21

10 几何与文字评价结果 22

11 几何校正对比图 24

12 几何校正复现与资料限制 27

第三部分 项目三图像压缩 29

13 数据、编码方法和评价口径 29

14 完整 24 张的压缩结果 30

15 压缩重建对比图 32

16 压缩项目复现 38

第四部分 提交与复核 40

17 提交材料清单和复现边界 40

报告说明

本报告包含课程的三项实习。第一项从传统 ISP 和 U-Net 开始，使用 SIED 预训练模型恢复极暗 RAW，再增加 NAF 精修和自适应色彩表。第二项比较传统页面校正、UVDoc 曲面展平和 PageMaskUNet 自动页面分割。第三项比较 JPEG、自研 DCTC 和 Cheng2020 学习式压缩。

表 1 三个项目的主要结果和评价范围

项目	评价范围	主要结果
图像增强	Canon 全部 1000 张	PSNR 26.707356 dB, SSIM 0.843515758, LPIPS 0.324355896
几何校正	自动方法隔离 22 张	分割 IoU 0.946106。校正后文本倾斜 7.103551 度，输入为 9.993837 度
图像压缩	Kodak 全部 24 张	Cheng-A Q6 为 0.805637 bpp，PSNR 36.704702 dB，SSIM 0.946863040，原始 RGB 压缩比 29.790094

图像增强的 1000 张包含训练图，不能解释为独立测试成绩。几何校正同时保存 200 张真值掩膜辅助实验和 22 张自动方法测试，二者分开列出。压缩比按实际码流计算，并注明学习模型的统计不含共享模型和容器头。

附件包括固定代码快照、全部轻量指标、复现脚本、已有自训增强权重和本报告 LaTeX 工程。GeoCorrection 原始 200 对图像及其自训分割权重当前未在工作目录中找到，因此几何部分的历史分数可以复核，完整推理还需要恢复资料。报告没有将缺失文件写成已经附带。本文未重新启动云机，也没有追加另外两项训练。

第一部分 项目一极暗图像增强

1 实验任务和完成范围

课程课件要求读取 SIED 数据，将低光 RAW 图像增强为正常曝光图像，并计算 PSNR、SSIM 和 LPIPS。三个指标应在 1000 张图像全部增强后汇总。报告还应包含源代码、部署说明和增强前后的对比图。

本轮完整评价对象为 Canon 0.0001 子集，共 1000 对图像。课件同时提供 Sony 0.001 子集。Sony 的历史结果来自 87 张官方测试图，本轮没有补算 Sony 全部 1000 张。两者的数量和用途在本报告中分开记录。

表 2 课程要求与本轮交付

课程要求	本轮实际交付
数据集读取	1000 对配对审计、RAW 读取、归一化和四通道打包
模型与算法设计	传统 ISP、U-Net、官方 SIED、光度精修、NAF 精修和色彩表实验
完整质量评价	Canon 1000 张的 PSNR、SSIM、LPIPS 及五项颜色指标
结果可视化	12 组样例，包含低光预览、传统方法、基线、最终结果、参考图及局部图
可复现材料	固定代码版本、数据清单、环境、参数、逐图指标、自训权重和官方权重获取说明
Sony 完整 1000 张	本轮未补齐，历史 87 张测试结果单独列出

2 数据读取和评价方法

2.1 RAW 数据和配对检查

Canon RAW 尺寸为 3840 乘 2160。文件没有图像头，数据类型为无符号 16 位整数。每个 RAW 文件应为 16,588,800 字节。黑电平为 512，白电平为 16383。图像按下式归一化，并将结果限制在 0 到 1 之间。

$$r = \mathrm{clip}\left(\frac{r_{\mathrm{raw}} - 512}{16383 - 512}, 0, 1\right). \tag{1}$$

之后按 RGGB 排列打包为四通道。四通道分别保存 R、R 行中的 G、B 和 B 行中的 G。参考图为正常曝光 RGB 图像。输入和参考图的配对关系由清单文件确定，不用文件遍历顺序猜测。

1000 对图像的文件大小、尺寸和配对检查全部通过。没有重复配对和缺失图像。审计检查的总字节数为 18,669,533,292。数据不符时程序停止，不通过强制缩放掩盖尺寸问题。

2.2 训练、验证和测试划分

采用 SIED 作者仓库的固定测试划分 [1]。官方训练部分为 924 张，官方测试部分为 76 张。在 924 张中，以种子 20260930 分出 92 张验证图，剩余 832 张用于附加模型训练。

表 3 本轮固定数据划分

用途	数量	清单文件
训练	832	`manifests/enhancement/canon_train.txt`
验证	92	`manifests/enhancement/canon_val.txt`
测试	76	`manifests/enhancement/canon_test.txt`
总体	1000	`manifests/source/canon_all.txt`

原始 RAW 路径、参考图路径和图像编号在三个部分之间互不重复。官方基础模型曾在官方训练部分预训练，其中包含本项目的 92 张验证图。因此，验证图只对新增分支的训练独立。1000 张的总体成绩也包含训练数据，不能用于说明独立场景的泛化能力。

76 张测试图曾在项目早期用于传统 ISP、U-Net 和旧精修方法的报告。本次模型选择结束后只执行一次新的测试评价。这里不将它称为项目历史上的首次测试。

2.3 主指标的计算

所有主指标均来自保存为 8 位 PNG 之前的浮点预测。预测和参考图采用 0 到 1 的 RGB 数值，并保持 3840 乘 2160 的原生尺寸。

对第 i 张图像，均方误差和 PSNR 定义为

$$\mathrm{MSE}_i = \frac{1}{3HW} \sum_{h,w,c} (x_{i,h,w,c} - y_{i,h,w,c})^2, \tag{2}$$

$$\mathrm{PSNR}_i = -10 \log_{10}(\mathrm{MSE}_i). \tag{3}$$

1000 张平均 PSNR 按下式计算。SSIM 和 LPIPS 也先逐图计算，再取图像均值。

$$\overline{\mathrm{PSNR}} = \frac{1}{1000} \sum_{i=1}^{1000} \mathrm{PSNR}_i. \tag{4}$$

先把所有像素的 MSE 合并后再取对数会得到另一种统计量。它没有用于本报告。按三个部分的均值计算总体时，权重分别为 832/1000、92/1000 和 76/1000。

SSIM 调用 scikit-image 0.26.0 中的 `structural_similarity`，设置 `data_range=1.0` 和 `channel_axis=-1`。没有额外裁边，也没有改成单独的亮度通道。其余参数使用该版本默认值。

LPIPS 使用 AlexNet 版本。RGB 先由 0 到 1 映射到负 1 到 1，然后输入固定评价网络。LPIPS 越低，表示该评价模型判断的感知差异越小。本文没有将它当作 PSNR 或 SSIM 的替代结果。

2.4 颜色指标和异常处理

补充指标包括平均 CIEDE2000 色差、逐图色差 P95 的均值、亮度 MAE、饱和度 MAE 和色相误差。颜色指标在最长边为 960 像素的副本上计算。缩放使用双线性插值和抗混叠。它们的分辨率与原生 PSNR 和 SSIM 不同。

色相采用环形距离。只在参考图饱和度至少 0.1、亮度至少 0.05 的像素上计算色相误差，再换算为度。没有满足条件的像素时，按既定实现记为 0。程序要求 1000 个编号唯一、划分正确、全部指标有限。异常值会导致检查失败，不会被静默删除。

3 算法设计和训练设置

3.1 传统方法和早期学习方法

传统 ISP 依次完成黑电平校正、去马赛克、灰世界白平衡、自动曝光、Gamma 变换和数值限制。Canon 正式传统基线使用 Gamma 2.0、亮度第 98 百分位、目标亮度 0.9 和白平衡指数 1.0。逐图曝光和白平衡只读取低光输入，不读取参考图。

早期 Residual U-Net 接收四通道 RAW。网络末端输出 12 通道，再用 PixelShuffle 恢复三通道全分辨率图像。模型约有 1789 万参数。训练 RAW 块为 256 乘 256，对应 RGB 块为 512 乘 512。批量大小为 4，优化器为 AdamW，初始学习率为 10^{-4}。主损失包含 L1、SSIM 和色度误差。历史 Canon 最优权重来自第 3000 步。该结果只作为早期 76 张测试记录，不写入 1000 张主表。

3.2 官方 SIED 和光度精修

SIED 使用作者发布的预训练权重 [1]。恢复过程只输入低光 RAW。自适应照明校正模块先处理曝光，再由扩散模型恢复 RGB 信息。当前设置为 20 步 DDIM 和三次独立采样平均。第 i 张原划分内图像、第 j 次采样的种子为

$$s_{i,j} = 3407 + i + 1000003j, \qquad j = 0, 1, 2. \tag{5}$$

索引在各自划分内部计算，不改为 1000 张的总索引。固定种子帮助保持同一设置，但跨 GPU 和 CUDA 版本仍可能有数值差异。

全场景光度精修根据低分辨率整图预测曝光、Gamma、白平衡、颜色矩阵和低频照度。初始变换为恒等变换，参数变化受限。v2 版本使用批量大小 8、学习率 2×10^{-5}、BF16 和 1500 步训练。它只作为后续模型的起点和历史对照。

3.3 RAW 引导 NAF 精修

结构分支借鉴 NAFNet 的设计 [2]。RGB 和上采样后的四通道 RAW 组成七通道输入。网络宽度为 48，编码块数为 2、2、4，中间为 6 块，解码块数为 2、2、2。残差最大幅度由 $0.35\tanh(\cdot)$ 限制。RAW 增益使用整图均值，目标均值 0.1，最大增益 4096。输出头从零初始化。

前期共运行五个阶段。NAF 阶段使用 AdamW、余弦学习率、EMA 0.999、批量大小 1 和 FP16。各阶段的主要参数见表4。缩略图验证、快速原生验证和完整原生验证分别保存，不混成一个成绩。

表 4 NAF 五阶段的主要设置

阶段	实际步数	学习率	训练和评价设置
阶段一	20000	2×10^{-4}	长边 768 缩略图训练，完整 92 张原生复核
阶段二	2500	5×10^{-5}	在线原生预测，512 RGB 块，冻结光度分支
阶段三	2000	2×10^{-5}	继续微调，使用 MSE 主导目标
阶段四	20000	2×10^{-5}	原生盲预测缓存，512 块，全场景 RAW 均值
阶段五	3000	2×10^{-5}	整图光度冻结，512 块，原生验证后早停

阶段四被选为冻结基线。它训练完成后的最佳权重仍接近训练起点。阶段五也没有选中新增训练步的权重。增加训练次数没有带来持续改善，报告保留这一结果。

3.4 TLC 局部聚合对照

TLC 针对训练小块和整图推理的全局统计差异 [3]。本轮只转换 NAF 结构分支，窗口为 512，积分图使用 FP32。固定 12 张验证图的 PSNR 由 26.952234 降为 26.853515 dB。该设置未通过门槛，因此没有继续进行 92 张完整验证，也没有用于最终模型。

3.5 自适应三维色彩表

自适应色彩表参考图像自适应 3DLUT 的方法 [4]。本项目使用独立的 PyTorch 实现，没有使用 FiveK 权重和旧 CUDA 扩展。表格每轴有 17 个格点，使用 3 个基底，RGB 残差上限为 0.12。小型 CNN 根据整图内容给出基底权重。附加模型共有 63,324 个参数。

系数先根据最长边 512 的整图上下文计算。控制器再读取最长边 128 的内容。所有原生图像块查询同一张色彩表，不在每个小块上重新估计色调。色彩表从恒等变换开始，官方 SIED 和 NAF 权重保持不变。

训练输入为 832 张训练图的 FP32 成对缩略图，尺寸 512 乘 288。批量大小为 16。使用 FP32、fused AdamW、初始学习率 3×10^{-4}、权重衰减 10^{-4} 和梯度范数限制 1。余弦学习率最低为 10^{-5}。损失为逐图 RGB log-MSE 加 0.1 倍平滑和单调约束。训练上限

1500 步，每 250 步检查相同的 12 张原生验证图。训练含周期验证的时间上限为 45 分钟。

候选相对当前已保存权重至少再提高 0.01 dB 时才更新。因此，最终保存第 1250 步。第 1500 步的快速验证略高，但增幅不足更新门槛。完整 92 张成绩对应第 1250 步权重。

3.6 低秩色彩表和成对实验

本轮也参考 SVDLUT 的分解思想 [5]，实现 RG、RB 和 GB 三个二维表的低秩表示。rank 设为 4。低秩附加模型共有 22,779 个参数，比 global3d 少约 64%。它仍会重建小型三维表，再使用同一种插值查询。它没有包含论文中的空间或双边分支。

global3d 和低秩模型采用相同控制器初值、私有批次随机序列、精度、优化器、损失和 1000 步上限。每个模型的训练含周期验证最多 15 分钟。完整 92 张验证在训练结束后执行。两个模型都通过候选门槛。低秩模型的质量稍低，完整 1000 次训练更新的平均步时也更长。

4 模型选择和实验结果

4.1 验证门槛和冻结顺序

候选需要在原生验证图上满足以下条件。

1. 平均 PSNR 比冻结基线至少提高 0.02 dB。
2. SSIM 下降不超过 0.002。
3. 各项颜色误差和 LPIPS 的增幅不超过 2%。
4. 完整 92 张记录、权重和文件哈希一致。

通过快速验证后才执行完整 92 张验证。合格候选中选择 PSNR 最高者。只有 PSNR 精确相同时，才比较 SSIM。

表 5 完整 92 张验证的候选比较

方法	所选步 / 实际步	附加参数量	PSNR / dB	SSIM
冻结基线	不适用	0	26.636931	0.85627188
自适应 3DLUT	1250 / 1500	63,324	26.842980	0.85626056
global3d 对照	750 / 1000	63,324	26.799789	0.85630565
低秩 rank4	1000 / 1000	22,779	26.782930	0.85619018

选择结果为第一组第 1250 步自适应色彩表。2026 年 10 月 24 日 22 时 54 分 58 秒保存最终参数和文件哈希，之后开始完整 1000 张验收。新测试分数没有参与选择。两个研究组都已结束，没有追加第三组训练。

表 6 完整 92 张验证的补充指标

指标	冻结基线	自适应 3DLUT	global3d 对照	低秩 rank4
LPIPS	0.31336739	0.31313677	0.31315882	0.31359197
平均色差	4.496330	4.473077	4.475649	4.493532
色差 P95 的图像均值	7.831748	7.851426	7.847209	7.852467
亮度 MAE	4.455134	4.419811	4.424134	4.442064
饱和度 MAE	0.03374167	0.03310769	0.03323075	0.03348335
色相误差 / 度	11.346907	11.199809	11.206710	11.268015

第一组训练 1500 步，第二组每个模型训练 1000 步，批次和调度也有差别。因此，第一组和第二组的分数差不能单独归于显存常驻。成对实验内的 global3d 和低秩对照更适合分析参数化的影响。

4.2 完整 1000 张的提交成绩

最终 1000 张平均 PSNR 为 26.707356 dB。平均 SSIM 为 0.843515758，平均 LPIPS 为 0.324355896。三个结果均由 1000 个逐图指标取算术平均得到。

表 7 完整 1000 张的基线和最终结果

指标	基线 1000 张	最终 1000 张	最终值减基线
PSNR / dB	26.554490	26.707356	+0.152867
SSIM	0.84355310	0.84351576	-0.00003734
LPIPS	0.32444085	0.32435590	-0.00008495
平均色差	4.595405	4.575388	-0.020018
色差 P95 的图像均值	8.165957	8.169354	+0.003397
亮度 MAE	4.458091	4.433654	-0.024438
饱和度 MAE	0.03768485	0.03725874	-0.00042611
色相误差 / 度	11.926284	11.887847	-0.038438

PSNR 提高 0.152867 dB。SSIM 下降 0.00003734。平均色差、亮度、饱和度、色相和 LPIPS 略有改善，色差 P95 略有上升。该结果没有达到 30 dB。

逐图 PSNR 有 524 张提高、476 张下降。变化的中位数为 0.105085 dB，最小值为负 1.752339 dB，最大值为 4.137213 dB。SSIM 有 497 张提高、503 张下降。所有图像都计入总体，没有筛除下降样例。

4.3 三个部分的结果

表 8 最终模型的分项结果

指标	训练 832 张	验证 92 张	测试 76 张
PSNR / dB	27.011915	26.842980	23.209062
SSIM	0.84743960	0.85626056	0.78513208
LPIPS	0.32044560	0.31313677	0.38074438
平均色差	4.362747	4.473077	7.027098
色差 P95 的图像均值	7.781651	7.851426	12.798538
亮度 MAE	4.249130	4.419811	6.470454
饱和度 MAE	0.03495672	0.03310769	0.06748473
色相误差 / 度	10.778889	11.199809	24.860905

训练部分平均 PSNR 为 27.011915 dB。验证部分为 26.842980 dB。

留出测试为 23.209062 dB，比基线低 0.086934 dB，SSIM 低 0.00067038。测试中 22 张 PSNR 提高，54 张下降。

这说明本次色调校正在训练和验证中的平均收益，没有变成留出测试收益。验证图又存在官方预训练暴露。因此，总体分数应与分项一起阅读。不能用 26.707356 dB 说明独立测试已经达到这一水平。最终方案已经冻结，本轮没有再按测试分数更换权重。

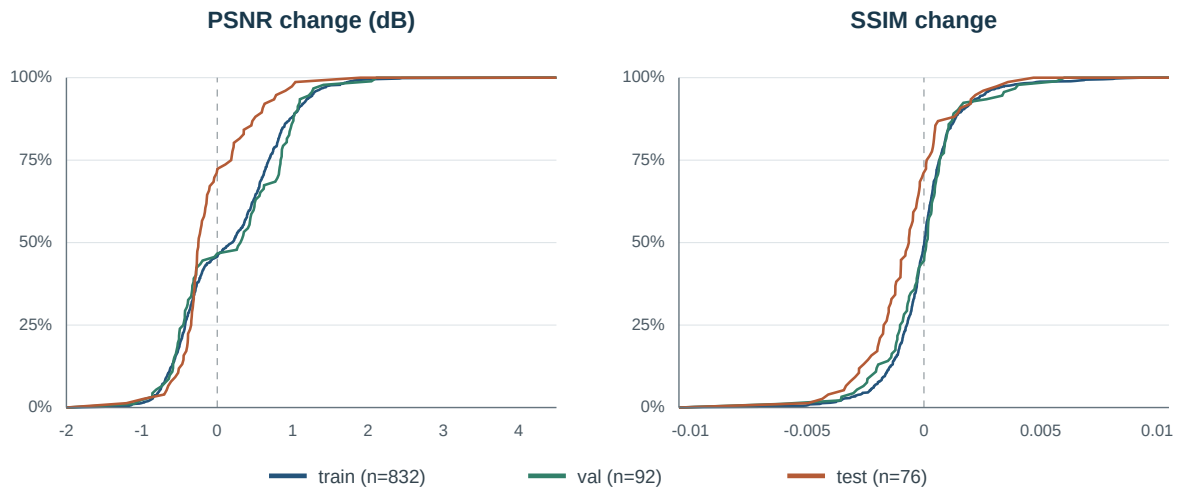

图 1 逐图指标变化的累计分布。横轴为最终值减基线值，纵轴为各部分内部的图像占比。零线左侧表示下降。PSNR 和 SSIM 越大越好。三条曲线分别使用 832、92 和 76 张图像。

新最终 1000 张全部在 RTX4090 上评价。历史基线的训练和验证结果来自 4090，76 张测试复用 4080 SUPER vGPU 的封存记录。硬件不同是比较的限制之一。最终 92 张验证重放与选择模型前的 92 张结果逐图一致，全部 8 项指标的最大绝对差为 0。

4.4 早期 76 张 Canon 测试记录

表 9 早期 Canon 测试结果，数量均为 76 张

方法	PSNR / dB	SSIM	LPIPS
自动传统 ISP	13.739991	0.13553439	0.91636975
Residual U-Net	16.123392	0.62203754	0.63799402
官方 SIED 三次平均	22.169954	0.78170272	未计算
SIED 和光度精修 v1	22.905984	0.78611727	未计算
SIED 和光度精修 v2	22.997996	0.78676497	未计算
阶段四 NAF 基线	23.295996	0.78580246	0.38010382
本轮最终色彩表	23.209062	0.78513208	0.38074438

这些结果的阶段和指标实现有历史差异。表中没有将未计算的 LPIPS 填为零。它们也没有被替换成 1000 张成绩。Sony 的 87 张历史记录在代码库原报告中保留，本轮没有给出 Sony1000 张的总体值。

表 10 Sony 的 87 张历史测试记录

方法	PSNR / dB	SSIM	LPIPS
自动传统 ISP	14.298588	0.16415948	0.86546771
Residual U-Net	17.051680	0.63324569	0.69637270

Sony 传统设置为 Gamma 1.8、分位数 99、目标 0.9 和白平衡指数 1.0。上表来自已保存 CUDA 摘要，与本机 MPS 复现的末位数值略有差别。它仍只包含 87 张，不能写成 Sony 全部 1000 张。

5 可视化比较

12 组样例均来自 76 张测试图。前 6 组按历史固定顺序。后 6 组从其余图像的 PSNR 变化排序中取 6 个等距位置，覆盖提高与下降。样例不参与模型选择或总体统计。

RAW 和 ISP 列从封存图截取。RAW 预览使用曝光 1 和 Gamma 2.2。ISP 示意使用 Gamma 2.2、分位数 99 和目标 0.9，与正式传统基线参数不同。基线与最终图来自原生 PNG，参考来自原 JPG。展示只做等比例缩放，不改变色调。局部区域统一为 $(1280, 720)$ 至 $(2560, 1440)$。分数读取原生浮点记录。

样例 1，图像 6

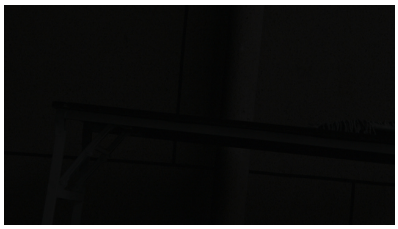

低光 RAW 预览

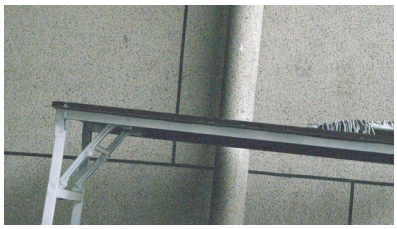

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 26.7293 变为 27.0823 dB。
SSIM 由 0.725678 变为 0.725140。
LPIPS 由 0.347511 变为 0.348731。

本例 PSNR 提高 0.3530 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 2，图像 8

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 28.4444 变为 28.4371 dB。
SSIM 由 0.837431 变为 0.840545。
LPIPS 由 0.306639 变为 0.305889。

本例 PSNR 下降 0.0073 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 3，图像 10

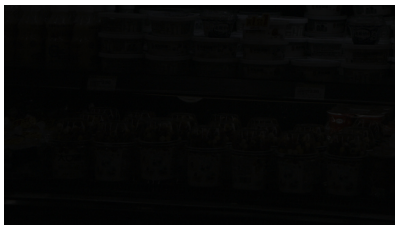

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 29.3118 变为 29.2635 dB。
SSIM 由 0.861883 变为 0.861425。
LPIPS 由 0.299394 变为 0.298354。

本例 PSNR 下降 0.0482 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 4，图像 14

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 28.3187 变为 28.5358 dB。
SSIM 由 0.887971 变为 0.888086。
LPIPS 由 0.265167 变为 0.263989。

本例 PSNR 提高 0.2171 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 5，图像 21

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 27.1846 变为 27.7754 dB。
SSIM 由 0.917327 变为 0.917800。
LPIPS 由 0.122112 变为 0.122196。

本例 PSNR 提高 0.5909 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 6，图像 28

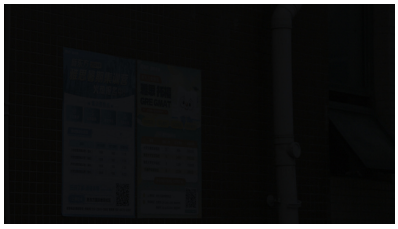

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 28.5727 变为 29.4779 dB。
SSIM 由 0.922125 变为 0.922508。
LPIPS 由 0.213063 变为 0.212844。

本例 PSNR 提高 0.9052 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 7，图像 127

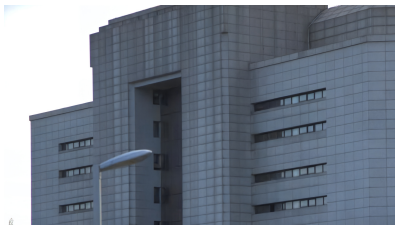

冻结基线，整幅图像

最终 LUT 方案，整幅图像

参考图，整幅图像

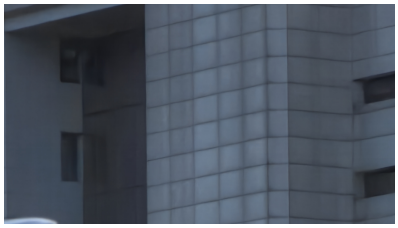

冻结基线，相同中心区域

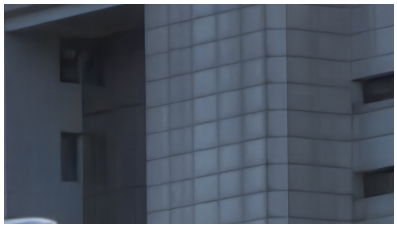

最终 LUT 方案，相同中心区域

参考图，相同中心区域

PSNR 由 27.4594 变为 26.2552 dB。SSIM 由 0.924177 变为 0.922291。LPIPS 由 0.302568 变为 0.303303。

本例 PSNR 下降 1.2042 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 8，图像 57

冻结基线，整幅图像

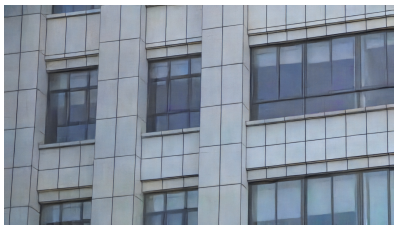

最终 LUT 方案，整幅图像

参考图，整幅图像

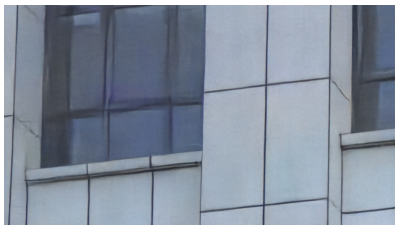

冻结基线，相同中心区域

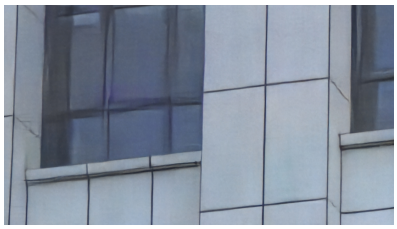

最终 LUT 方案，相同中心区域

参考图，相同中心区域

PSNR 由 17.7879 变为 17.3965 dB。SSIM 由 0.846605 变为 0.844626。LPIPS 由 0.268805 变为 0.270943。

本例 PSNR 下降 0.3914 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 9，图像 671

冻结基线，整幅图像

最终 LUT 方案，整幅图像

参考图，整幅图像

冻结基线，相同中心区域

最终 LUT 方案，相同中心区域

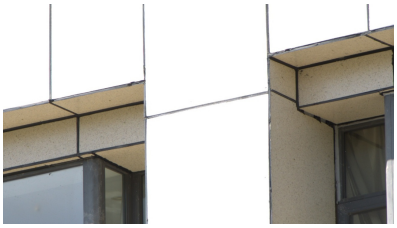

参考图，相同中心区域

PSNR 由 17.1841 变为 16.8853 dB。SSIM 由 0.853089 变为 0.851863。LPIPS 由 0.266117 变为 0.265603。

本例 PSNR 下降 0.2988 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 10，图像 904

冻结基线，整幅图像

最终 LUT 方案，整幅图像

参考图，整幅图像

冻结基线，相同中心区域

最终 LUT 方案，相同中心区域

参考图，相同中心区域

PSNR 由 20.3978 变为 20.1891 dB。SSIM 由 0.693136 变为 0.692489。LPIPS 由 0.498721 变为 0.500044。

本例 PSNR 下降 0.2086 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 11，图像 680

冻结基线，整幅图像

最终 LUT 方案，整幅图像

参考图，整幅图像

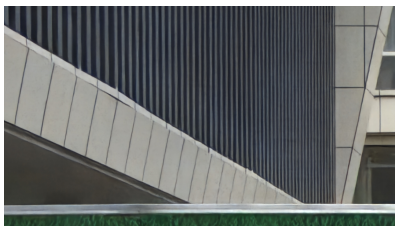

冻结基线，相同中心区域

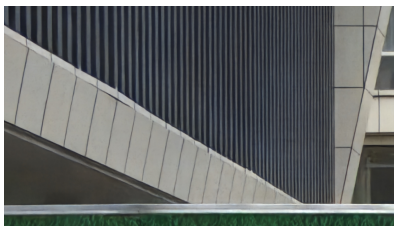

最终 LUT 方案，相同中心区域

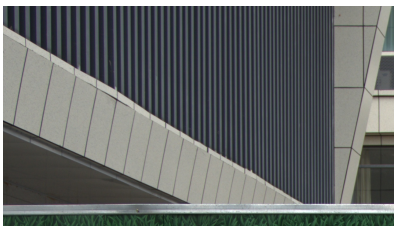

参考图，相同中心区域

PSNR 由 29.8102 变为 30.0038 dB。SSIM 由 0.827411 变为 0.827499。LPIPS 由 0.274839 变为 0.274941。

本例 PSNR 提高 0.1936 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

样例 12，图像 141

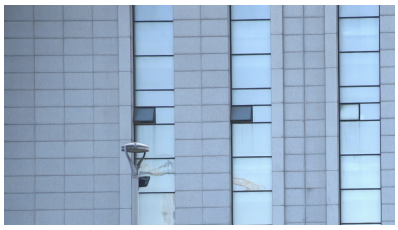

冻结基线，整幅图像

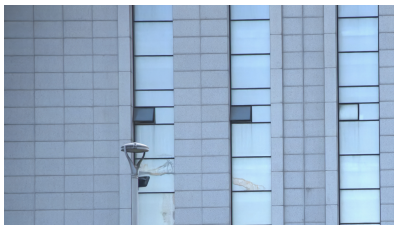

最终 LUT 方案，整幅图像

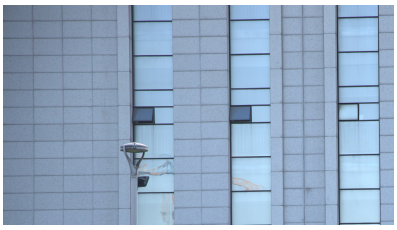

参考图，整幅图像

冻结基线，相同中心区域

最终 LUT 方案，相同中心区域

参考图，相同中心区域

PSNR 由 29.3229 变为 31.2216 dB。SSIM 由 0.835638 变为 0.835881。LPIPS 由 0.299020 变为 0.299288。

本例 PSNR 提高 1.8988 dB。图像仅为排版等比例缩放，所有分数来自封存的原生浮点评价。

6 速度、资源和验证

924 张训练和验证图的盲扩散基础输出保存为原样 FP32 缓存。后续候选复用缓存，避免重复执行扩散。约 86 GiB 基础缓存和约 3 GiB 训练缩略对可以重新生成。本机没有下载这些大缓存，但保留了逐图哈希、种子和生成代码。

832 张 FP32 训练对常驻 GPU 时占 2,944,401,408 字节。一次预加载用时 2.448222 秒。短测使用 4 次预热和 16 次计时更新，批量大小 16。

表 11 真实训练批次短测

数据方式和模型	平均秒/步	附加参数量
pinned DataLoader 和 global3d	0.03469200	63,324
显存常驻和 global3d	0.01299559	63,324
显存常驻和低秩 rank4	0.01302303	22,779

同一个 global3d 模型的短批次吞吐约为原来的 2.669521 倍。首个预测完全一致，20 次更新后参数最大绝对差为 1.0766×10^{-6}。这个测量不含完整原生验证和预加载摊销，不能说明整次训练都提高相同比例。

完整 1000 次训练更新的平均步时为 global3d 0.01239057 秒、低秩 0.01373014 秒。低秩约慢 10.81%。包含周期验证的阶段分别用时 251.85396 秒和 252.78675 秒，均不含之后的完整 92 张验证。参数更少没有在本轮带来速度优势。

NAF 的另一组合成数据短测中，channels-last、FP16 和 fused AdamW 的吞吐为原来的 1.168 倍。单独使用 channels-last 更慢。该结果与色彩表短测来自不同模型，不能相乘。

最终 1000 张评价在 2026 年 10 月 25 日 01 时 28 分 07 秒结束。训练和验证从缓存重放，测试包含新扩散。因此，CSV 中的混合时长不用于表示统一的端到端单图速度。

新方法完整回归 176 项通过，最终 1000 张约束相关的 20 项针对性测试通过。结果还经过独立复核，包括 1000 个编号、划分、种子、模型哈希、逐图指标和 PNG 尺寸。1000 张 PNG 的 SHA256 及 3840 乘 2160 尺寸全部一致。目录级 checksum 检查没有差异。

7 代码、模型权重和复现步骤

7.1 提交文件的组织

报告配套材料包括 LaTeX 工程、最终 PDF、代码与指标包、自训模型权重包。代码包固定到 `beebb3454e99f039dfd98bc848aa7fafb9772f46`。新增 PDF 排版脚本单独保存，不修改已冻结的推理源文件。

表 12 核心文件

用途	文件
RAW 和 RGB 读取	src/dip_course/io.py
正式指标	src/dip_course/metrics.py
官方 SIED 推理	src/dip_course/cli/infer_official_sied.py
NAF 精修	src/dip_course/enhancement/refiner.py
色彩表	src/dip_course/enhancement/adaptive_lut.py
低秩表	src/dip_course/enhancement/factorized_lut.py
基线和缓存	cloud/evaluate_sied1000.py
两组研究	cloud/research_sied_color.py 和cloud/research_sied_iccv.py
最终 1000 评价	cloud/finalize_sied_submission1000.py
逐图提交指标	reports/assets/enhancement/submission1000_20261024/metrics.csv

全部 1000 行 CSV 作为独立附件保存，没有只保留总体。它包含原始浮点指标、图像编号、划分、种子、预测来源和 PNG 哈希。报告表格显示必要精度，CSV 保留原始精度。

7.2 模型权重

最终方案需要三个主要文件，分别为官方 SIED 权重、阶段四 NAF 权重和第 1250 步色彩表权重。自训 NAF 与色彩表已收入权重附件。两个低秩实验对照和旧光度 v2 也保留，便于核对实验。

官方 SIED 文件为 2,610,348,582 字节。它由 SIED 作者发布，应从原发布地址取得并核对 SHA256。它没有放入本项目自训权重包。历史上有不同封装的官方模型，文件哈希不同，不能仅凭文件名替换。

canon_naf_phase4.pt

文件大小为 36,230,265 字节。

SHA256 337acc11705e8ae1f170d22263161b210a0ed0d4272a647db4e82ccbb611f2d8

本项目训练的权重，已收入权重附件。

canon_color_lut_1250.pt

文件大小为 317,445 字节。

SHA256 2cfd72ec81addd4a091ea199c613c4bc47e27e562a098971db7302510a1db609

本项目训练的权重，已收入权重附件。

ablation_global3d_750.pt

文件大小为 316,869 字节。

SHA256 47580a832b66a43bcedf6276678f11a3a1969b47d15c9e2568bad1238f472323

本项目训练的权重，已收入权重附件。

ablation_pairwise_rank4_1000.pt

文件大小为 154,946 字节。

SHA256 7ab0c534f3b353adf919d35529679d1d27874a98d5bbdf0b9697c6f7cbfebda9

本项目训练的权重，已收入权重附件。

photometric_v2.pt

文件大小为 193,785 字节。

SHA256 0428cdb082979ed960cfd5925a78ae558a635dfd8eaf0f783023272f65b27afa

本项目训练的权重，已收入权重附件。

official_canon_0.0001.pt

文件大小为 2,610,348,582 字节。

SHA256 40014f1f71dfdcd9a8969074097f675a54d2598aec26b183c0874bfcd5c26238

由 SIED 作者发布。按原发布地址获取并核对哈希，未放入自训权重附件。

7.3 本机复算 1000 张均值

这一步只需要 Python 标准库和已提交的 CSV。它复算封存指标的汇总，不重新执行模型。可在解压后的项目根目录运行配套reproduce_statistics.py。

```
python3 reproduce_statistics.py
```

输出应包含 1000 张、832/92/76 划分和以下三个值。

```
psnr_mean  = 26.707356438407885
ssim_mean  = 0.8435157579481601
lpips_mean = 0.3243558964841068
```

脚本同时核对全部 8 项总体和分项均值、CSV 文件哈希和唯一编号。8 位展示 PNG 存在量化误差，不用于逐位复现浮点分数。

7.4 准备完整推理环境

实际环境为 Python 3.12.3、PyTorch 2.8.0 加 CUDA 12.8、torchvision 0.23.0、NumPy 2.3.2、Pillow 11.3.0、scikit-image 0.26.0 和 LPIPS 0.1.4。最终评价使用 RTX4090。FP16 原生恢复需要 CUDA 环境。本机 CPU 可以复算 CSV 和运行不依赖 CUDA 的检查。

以下命令供新建复现目录使用。不要在唯一原始资料目录中重复执行准备或覆盖操作。

```
cd project
python3.12 -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install torch==2.8.0 torchvision==0.23.0 \
  --index-url https://download.pytorch.org/whl/cu128
python -m pip install -e '.[sied,train,dev]' requests
python -m pip install numpy==2.3.2 Pillow==11.3.0 \
  scikit-image==0.26.0 lpips==0.1.4
```

这里的`project/` 来自代码与指标附件。它包含 `beebb345` 固定源码和单独列出的报告复现入口。若从 Git 克隆旧提交，还需复制附件新增的`reproduce_statistics.py`和`cloud/reproduce_sied_submission.py`，旧提交本身没有这两个新文件。

官方代码固定到提交 `fb7af94ac831e91c647415bf1ca0b1a75931833a`。准备 1000 对 RAW 和参考图，保留原配对清单。自训权重按附件中的恢复路径放置，官方文件按哈希核对。

```
git clone https://github.com/JianghaiSCU/SIED.git third_party/SIED-official
git -C third_party/SIED-official checkout --detach \
  fb7af94ac831e91c647415bf1ca0b1a75931833a
python -m dip_course.cli.audit_dataset \
  --data-root data/SIED_dataset \
  --manifest manifests/source/canon_all.txt \
  --output-json audit.json
```

7.5 从原始数据独立运行最终模型

附件新增`cloud/reproduce_sied_submission.py`。它直接读取固定的三个模型，对 1000 张 RAW 重新进行盲推理，不要求历史约 86 GiB 缓存。程序先检查权重、源码和清单哈希，逐图预测完成后才读取参考图评分。结果写入独立目录，不选择新模型。

解压自训权重包到项目根目录后，已有文件位于`submission_weights/`。官方模型另外放入`checkpoints/official/`。先使用训练部分前 3 张检查环境。

```
python cloud/reproduce_sied_submission.py \
  --data-root data/SIED_dataset \
  --official-repo third_party/SIED-official \
  --official-checkpoint checkpoints/official/canon_0.0001.pt \
  --refiner-checkpoint submission_weights/canon_naf_phase4.pt \
```

```
--lut-checkpoint submission_weights/canon_color_lut_1250.pt \
--output-dir outputs/reproduce_submission1000 --limit-new 3
```

确认 3 张完成后，再运行同一条命令并删除`--limit-new 3`。程序核对并跳过已有 3 张，继续到 1000 张。只有 1000 个唯一编号和全部有限指标齐全后，才生成总体汇总。它不会对测试图做试调，也不会按新测试分数更换模型。

该独立入口已完成本机语法、参数和固定资料检查，报告编写没有再次进行 CUDA 全量运行。原实验中训练和验证重放原样 FP32 缓存，独立入口会重新执行扩散。跨 GPU 和软件版本可能产生末位差异，不能承诺新浮点分数逐位相同。

原`cloud/finalize_sied_submission1000.py` 保留为历史封存入口。它还依赖旧基线、旧测试、两个研究组和原样缓存，适合核对原实验。不能只复制摘要后直接调用它重建缺失缓存。

固定权重推理与从头训练属于不同复现任务。前者用于核对已选模型，后者还受到 CUDA 算子、随机裁剪和学习过程的影响。相同种子无法保证跨硬件逐位一致。阶段一至三的旧逐图 CSV 没有完整迁移，只保留了摘要和权重，报告没有伪造这些缺失记录。

8 项目一结论和后续工作

本轮完成了 Canon 全部 1000 张的增强和评价。最终平均 PSNR 为 26.707356 dB，平均 SSIM 为 0.843515758，平均 LPIPS 为 0.324355896。PSNR 小幅提高，SSIM 略有下降。76 张测试的 PSNR 和 SSIM 也下降，因此仍需改善未见场景的颜色和亮度稳定性。

后续应准备未被官方预训练和本项目反复检查的开发验证场景。可以分别分析整图色调和局部细节误差。再对损失权重、残差幅度和空间感知色彩表做单项实验。每次只修改一个因素，并同时观察 SSIM 和颜色误差。现有 76 张测试不再用于反复挑选参数。

速度方面，优先使用已验证的 FP32 缓存复用和显存常驻。后续计时应包含数据预载、读取和完整验证。低秩模型在本轮参数更少，但速度更慢，不能只按参数量选择模型。扩散少步训练需要新的实验安排，本轮没有继续执行。

全部新权重、逐图指标、图片和日志已经完成本机备份。云机于 2026 年 10 月 25 日 01 时 37 分 24 秒正常关闭，随后两次 SSH 检查离线。实例磁盘和原始数据保留，定时监测已删除。报告编写没有重新开机或追加训练。

第二部分 项目二几何校正

9 任务、数据和方法

课件提供 GeoCorrection 的 200 张照片和同名页面掩膜。任务是处理页面的倾斜、透视、弯曲和折痕，并用图像和有效指标评价校正效果。数据没有对应的平整参考图，也没有人工文字转录。

七类文件分别有普通拍摄 53 张、时间戳拍摄 82 张、曲面 7 张、折痕 4 张、透视 4 张、旋转 3 张和书页 47 张。数据聚合 SHA256 为

```
5523dfb7b4ad5f053b88ed5648e3f446bcb879a91c231b731d660bd572746050
```

逐文件路径、尺寸和哈希保存在`manifests/geocorrection/pairs.csv`。该清单保留了实验对象，但无法代替原始图像。

9.1 传统页面校正

传统方法先根据页面掩膜寻找四角，再用单应性修正透视。随后分别沿列和沿行整理页面上下边与左右边。最后检测文本主方向，必要时旋转 90 度。长边限制为 1200 像素。该方法没有训练参数，但依赖输入掩膜的质量。

早期 200 张实验直接使用数据集的真值页面掩膜。它可以检查几何算法的能力，但不能代表无标注输入的自动处理效果。页面轮廓变直后，文字仍可能弯曲或被拉伸。

9.2 UVDoc 稠密展平和混合方法

UVDoc 根据照片预测反向网格，用于恢复页面内部的非线性形变 [6]。本项目使用公开预训练模型，输入为 712 乘 488，输出为 45 乘 31 网格，再对较高分辨率图像重映射。模型未在这 200 张图上继续训练。

该路线使用真值页面掩膜裁剪，边缘留量为 0.02。相同网格也作用于掩膜。混合方法在 UVDoc 结果上继续执行传统边界精修和方向校正。评价长边为 1200。UVDoc 和精修前后的图像均保留，用于观察页面外形和页内文字之间的取舍。

模型来自`PaddlePaddle/UVDoc_safetensors`，修订为

```
bfa6aad03b549c7e2cf89cefd2fb02ba3bef2ae4
```

权重 SHA256 为

```
65f980e3083b4919d962d7b4c8ddb42a926dc8b36f4909944746cf2d7b7325dc
```

历史环境为 PyTorch 2.8.0 加 CUDA 12.8 和 Transformers 5.19.0。模型获取地址为https://huggingface.co/PaddlePaddle/UVDoc_safetensors。

9.3 PageMaskUNet 自动页面分割

为了减少对真值掩膜的依赖，本项目训练 PageMaskUNet。它采用五层 U-Net，基础通道数为 32，使用 GroupNorm、SiLU、跳跃连接和双线性上采样。输入等比例缩放并补边到 512 乘 512。模型输出单通道页面概率，阈值为 0.5。预测概率先恢复到原图大小，再生成二值掩膜。

训练按七类文件分层，种子为 20261018。训练、验证和测试数量分别为 156、22、22。损失由 0.35 倍 BCE、0.50 倍 Dice 损失和 0.15 倍相邻差分边界损失组成。使用 AdamW，批量大小 8，初始学习率为 3×10^{-4}，权重衰减为 10^{-4}。余弦调度最低学习率为初始值的 0.03，梯度范数限制为 1。训练使用 4090 和 BF16。

训练最多 100 轮。验证 IoU 连续 20 轮没有提高时停止，实际完成 92 轮。第 72 轮的验证 IoU 最高。划分清单、逐轮日志和测试摘要均保留。预测掩膜用于驱动原有传统校正，自动方法的几何测试长边为 1400。

历史自动方法没有将预测掩膜继续接入 UVDoc。原 200 张 UVDoc 混合实验也没有改用预测掩膜。这两个结果应分别解释，不能合成为一个未经执行的新方法。

10 几何与文字评价结果

10.1 页面分割

IoU 计算预测区域与真值区域的交并比。Dice 计算两区域交集的两倍除以面积和。Precision、Recall 及边界 F1 也同时记录。分割表使用训练程序的 512 像素评价设置。恢复到原图后再次测量的边界值可能不同，不应直接替换表中的历史测试值。

表 13 固定划分的页面分割结果

集合	IoU	Dice	Precision	Recall	边界 F1
验证 22 张	0.968092	0.983033	0.990334	0.977638	0.854937
测试 22 张	0.946106	0.969335	0.954000	0.991670	0.787976

测试损失为 0.04056449，验证损失为 0.02820705。区域 IoU 较高，但边界 F1 为 0.787976。阴影、弯曲和页面附近背景仍会影响边缘位置。高召回也可能伴随多保留背景。

10.2 22 张自动方法测试

边界 RMSE 和 P95 按图像尺度归一化，描述页面边缘对直线的偏离。填充率为页面掩膜占输出矩形的比例。文本倾斜由 Hough 文本边缘主方向估计。倾斜角和边界误差越低，表示对应诊断更好。

表 14 相同 22 张测试图的几何结果

指标	预测掩膜输入	预测掩膜输出	真值掩膜输入	真值掩膜输出
边界 RMSE	0.01885140	0.01352458	0.00796000	0.00040299
边界 P95	0.03911691	0.03192278	0.01966474	0.00021211
页面填充率	0.411242	0.982870	0.398952	0.999790
文本倾斜 / 度	9.993837	7.103551	10.064026	6.096917

预测掩膜驱动的校正将平均文本倾斜由 9.993837 度降至 7.103551 度。平均校正时间为 3026.379731 毫秒，不含独立页面分割的全部开销。相同图像使用真值掩膜时，平均倾斜为 6.096917 度，平均校正时间为 2991.105506 毫秒。

两种设置的输入边界由不同掩膜测得。只能在各自设置内部比较输入和输出。预测掩膜的边缘误差会进入后续变换，因此与真值掩膜结果仍有明显差距。

10.3 200 张真值掩膜辅助实验

表 15 200 张历史几何实验

设置	边界 RMSE	边界 P95	填充率	倾斜 / 度
传统输入	0.00835700	0.02042421	0.412613	8.303751
传统校正	0.00036439	0.00023126	0.999773	5.845216
UVDoc 裁剪输入	0.01183585	0.02888562	0.755385	7.597270
UVDoc 输出	0.00540183	0.01223654	0.977840	5.327889
混合输出	0.00071432	0.00011874	0.999848	5.113268

传统方法与 UVDoc 使用不同的页面裁剪，因此两行输入指标不同。混合精修又有一次重采样和方向预处理，其程序内输入倾斜为 5.437830 度。表中分别保留原摘要值，没有将不同输入阶段写成完全一致的评价对象。

UVDoc 的平均模型前向为 4.816419 毫秒，高分辨率重映射及后处理为 1546.422740 毫秒，完整 UVDoc 处理为 2372.902562 毫秒。混合精修再增加 1718.833591 毫秒。CPU 重映射和后处理占用较多时间，单独加快网络前向的收益有限。

混合方法的外边界更规整，但部分曲面和折痕的文本倾斜变差。接近 1 的填充率只说明页面几乎铺满矩形，不能证明文字完全恢复。

10.4 固定 40 张 OCR 诊断

按七类文件固定抽取 40 张，使用相同 PP-OCRv6 medium 检测和识别模型。历史环境为 PaddleOCR 3.7.0、PaddleX 3.7.2 和 Transformers 5.19.0。长边为 1200，置信度阈值为 0.8。

表 16 40 张 OCR 可读性诊断

方法	文本行	高置信行	高置信字符	平均置信度	加权字符
输入	2,679	2,171	35,226	0.891321	36356.93
传统	2,292	1,530	24,860	0.828621	28945.42
UVDoc	2,966	2,541	42,689	0.913456	43765.28
混合	2,937	2,476	42,987	0.906133	43911.12

混合方法的高置信字符数比输入增加 22.03%。33 张增加、1 张持平、6 张减少。UVDoc 的平均行置信度较高，混合方法的字符总量较高。传统校正的高置信字符反而减少，说明边界变直不能代替文字内容检查。

数据没有人工转录，因此这些数值不能写成识别准确率、CER 或 WER。没有平整参考图，也不能把输入与校正图的 PSNR 或 SSIM 写成几何恢复质量。

11 几何校正对比图

下列 7 组四列图来自 200 张历史真值掩膜辅助实验，包含书页、拍摄、曲面、折痕、透视和旋转。最后一组来自自动方法的隔离测试。所有图均从已保存的对比图按原位置截取，未重新生成结果。

几何样例 1，150

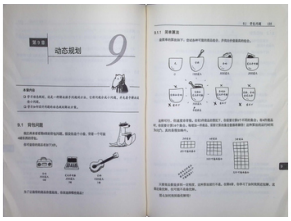

页面裁剪　　传统校正　　UVDoc　　UVDoc 后精修

四列来自同一封存样例。此组使用数据集掩膜辅助裁剪。

几何样例 2，20260401_103937

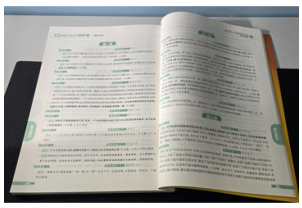

页面裁剪　　传统校正　　UVDoc　　UVDoc 后精修

四列来自同一封存样例。此组使用数据集掩膜辅助裁剪。

几何样例 3，IMG_20260326_105848

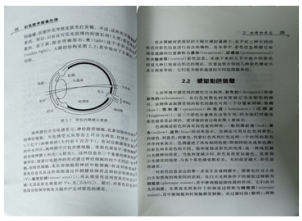
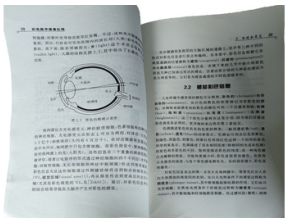
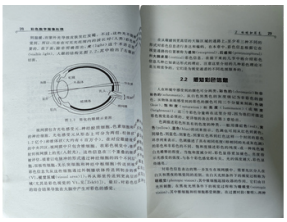

页面裁剪　　传统校正　　UVDoc　　UVDoc 后精修

四列来自同一封存样例。此组使用数据集掩膜辅助裁剪。

几何样例 4，dewarp20260728_curved_029

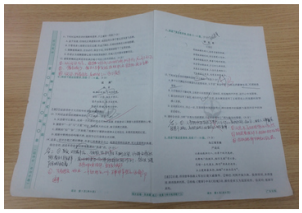
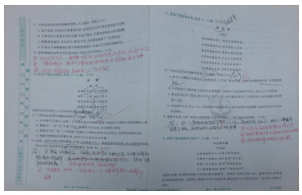
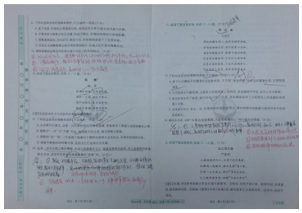
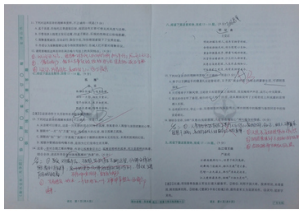

页面裁剪　　传统校正　　UVDoc　　UVDoc 后精修

四列来自同一封存样例。此组使用数据集掩膜辅助裁剪。

几何样例 5，dewarp20260728_fold_020

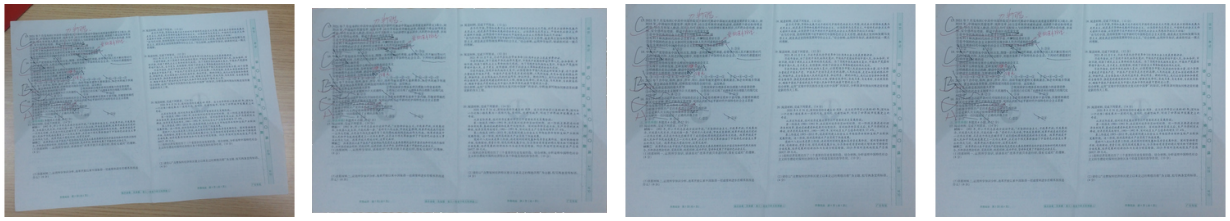

页面裁剪 传统校正 UVDoc UVDoc 后精修

四列来自同一封存样例。此组使用数据集掩膜辅助裁剪。

几何样例 6，dewarp20260728_perspective_019

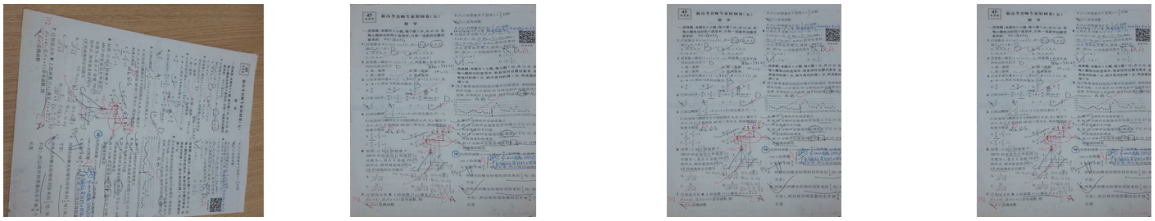

页面裁剪 传统校正 UVDoc UVDoc 后精修

四列来自同一封存样例。此组使用数据集掩膜辅助裁剪。

几何样例 7，dewarp20260728_rotate_018

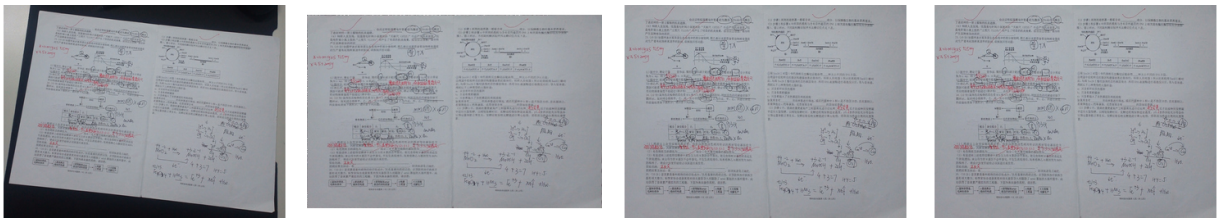

页面裁剪 传统校正 UVDoc UVDoc 后精修

四列来自同一封存样例。此组使用数据集掩膜辅助裁剪。

自动校正测试样例

原图、预测掩膜、单应性和边界校正依次列出。图像编号为 dewarp20260728_perspective_019。

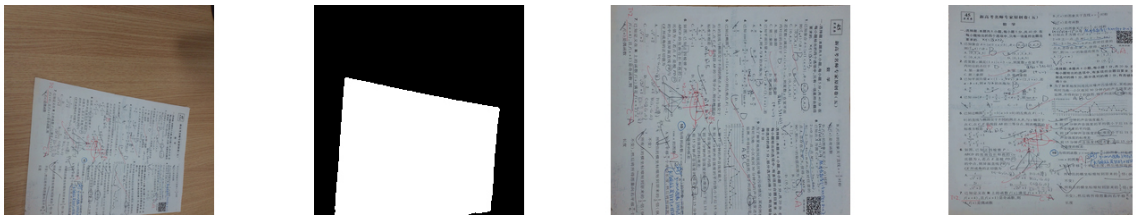

原始图像 预测掩膜 单应性 边界校正

该图来自 22 张隔离测试。其掩膜由 PageMaskUNet 预测。页面外边界更规整，页内形变仍有残留。

12 几何校正复现与资料限制

12.1 已有文件和缺失文件

代码包包含页面分割、传统变换、UVDoc 推理、OCR 评价、固定划分和逐图指标。历史 PageMaskUNet 文件应放在`checkpoints/geocorrection/page_mask_unet/best.pt`，原记录约 90 MB。其 SHA256 为

```
250789695f3c92b3acaa2c373fb6a51083cf0dfa54093ed3acd3c2cd084eccc6
```

该自训文件和原 200 对图像当前未在工作目录找到，未收入本次权重附件。已有 CSV 可以复算均值，但无法据此重新生成全部图像。恢复原数据和上述文件后才能执行相同权重的完整推理。若重新训练，得到的新权重和分数应另存，不能声称与历史权重逐位相同。

UVDoc 及 OCR 模型从原公开地址取得。OCR 文件哈希保存在`reports/assets/geocorrection/ocr/model_sha256.txt`，包含配置和两个模型文件。本文没有将公开模型误写为本项目训练。

12.2 准备环境和运行

在代码包的固定快照中安装几何依赖。数据目录下应有`images/` 和`mask/`，各 200 张。以下操作均写入新的复现目录。

```
python -m pip install -e '.[geometry-ml,geometry-ocr]'
python -m pip install transformers==5.19.0 \
  paddleocr==3.7.0 paddlex==3.7.2
dip-audit-geocorrection \
  --data-root data/geocorrection/GeoCorrection \
  --output-json outputs/reproduce_geo/audit.json \
  --output-csv outputs/reproduce_geo/pairs.csv --expected-count 200
dip-rectify-classical \
  --data-root data/geocorrection/GeoCorrection \
  --output-dir outputs/reproduce_geo/classical \
  --max-side 1200 --expected-count 200
```

恢复分割权重后，先预测固定测试 22 张。该入口读取数据集掩膜只用于计算分割指标，预测网络只输入 RGB 照片。后续校正明确使用预测掩膜。

```
dip-infer-page-segmentation \
  --data-root data/geocorrection/GeoCorrection \
  --checkpoint checkpoints/geocorrection/page_mask_unet/best.pt \
  --output-dir outputs/reproduce_geo/predicted \
  --split test --device cuda --precision bf16 --threshold 0.5
python -c 'import json; d=json.load(open("reports/assets/geocorrection/page_mask_unet/split.
    json")); print(",".join(d["test"]))'
```

将上一行打印的编号填入下方 `TEST_KEYS`。该变量仅由固定划分生成，不手工挑选

容易样例。

```
TEST_KEYS=$(python -c 'import json; d=json.load(open("reports/assets/geocorrection/
    page_mask_unet/split.json")); print(",".join(d["test"]))')
dip-rectify-classical \
  --data-root data/geocorrection/GeoCorrection \
  --mask-subdir "$(pwd)/outputs/reproduce_geo/predicted/masks" \
  --mask-source-label 'PageMaskUNet held-out predictions' \
  --keys "$TEST_KEYS" --expected-count 200 --max-side 1400 \
  --output-dir outputs/reproduce_geo/automatic_test
```

需要从头训练时使用下列设置。它用于复现训练方法，不能补回已丢失的同一个权重文件。

```
dip-train-page-segmentation \
  --data-root data/geocorrection/GeoCorrection \
  --output-dir outputs/reproduce_geo/training \
  --input-size 512 --base-channels 32 --epochs 100 \
  --batch-size 8 --learning-rate 3e-4 --weight-decay 1e-4 \
  --num-workers 4 --seed 20261018 --patience 20 \
  --device cuda --precision bf16 --require-cuda
```

UVDoc 和混合历史方法使用以下固定模型修订。

```
dip-infer-uvdoc \
  --data-root data/geocorrection/GeoCorrection \
  --output-dir outputs/reproduce_geo/uvdoc \
  --model-id PaddlePaddle/UVDoc_safetensors \
  --model-revision bfa6aad03b549c7e2cf89cefd2fb02ba3bef2ae4 \
  --device cuda --expected-count 200
dip-rectify-classical \
  --data-root outputs/reproduce_geo/uvdoc \
  --image-subdir rectified --mask-subdir rectified_masks \
  --output-dir outputs/reproduce_geo/hybrid \
  --max-side 1200 --expected-count 200
dip-eval-geocorrection-ocr \
  --data-root data/geocorrection/GeoCorrection \
  --keys-manifest manifests/geocorrection/ocr_test_40.txt \
  --classical-dir outputs/reproduce_geo/classical/corrected \
  --uvdoc-dir outputs/reproduce_geo/uvdoc/rectified \
  --hybrid-dir outputs/reproduce_geo/hybrid/corrected \
  --output-dir outputs/reproduce_geo/ocr40 \
  --device gpu --engine transformers --max-side 1200
```

后续可以先改善页面边缘，再将预测掩膜接入 UVDoc。需要另建有人工文字转录的评价集，检查局部拉伸是否影响识别。上述方向尚未执行，不计入本报告成绩。

第三部分 项目三图像压缩

13 数据、编码方法和评价口径

Kodak 共有 24 张 8 位 RGB PNG。18 张为 768 乘 512，6 张为 512 乘 768。每张均有 393216 个像素。原 PNG 总大小为 15,394,305 字节，未压缩 RGB 总量为 28,311,552 字节。

数据来自课程入口指向的 Kodak 仓库，固定提交如下。

```
dd2e1105fe8d9afe1120cd7e4c0e5e41f509a81b
```

聚合哈希为

```
b2194c51cff99d6f3cc14fa73c0a805817b1e705abc02cf94f89165cc5e6bcc5
```

学习式实验记录的清单哈希如下。

```
900976cefbe968ace159eab8a39afd0411fed99e8ffb83c0dea097d1723c77fa
```

两个程序的清单组织方式不同，不能据此直接断定图像内容不同。复现时应核对逐文件哈希，清单位于`manifests/compression/kodak.sha256`。

13.1 四种已经执行的方法

JPEG 基线通过 Pillow 调用 libjpeg，使用 4:2:0 色度抽样，质量档为 30、50、70 和 90。质量因子 Q 用于控制量化强度。Q 本身不表示 PSNR，也不表示固定压缩比。不同模型的 Q 不是相同的数值尺度。

自研 DCTC 先将 RGB 变为 YCbCr，再进行 4:2:0 抽样、8 乘 8 正交 DCT、质量缩放量化、Zigzag 和 DC 差分。v1 使用 AC 零游程和 zlib DEFLATE。v2 采用向量化处理，删除末尾零系数，再打包 int16 系数并使用较快的 zlib 级别。两个版本都有独立的码流和解码程序，不依赖原图完成解码。

Cheng2020 Anchor 使用 CompressAI 1.2.8 公开 MSE 预训练模型 [7, 8]。测试 Q1、Q3 和 Q6。模型使用神经网络变换、超先验和自回归上下文来编码潜变量。Kodak 只用于本项目测试，没有用于模型再训练。报告没有把 Anchor 版本写成额外执行过的 Attention 版本。

13.2 压缩比和码率公式

设全部图像的实际编码字节之和为 B，总像素数为 P，则

$$\mathrm{bpp} = \frac{8B}{P}, \qquad R_{\mathrm{RGB}} = \frac{3P}{B}, \qquad R_{\mathrm{PNG}} = \frac{15394305}{B}. \tag{6}$$

原始 RGB 空间节省率为 $100(1 - B/(3P))$。压缩比越大，体积越小。表中的压缩比均为全部文件总字节相除，没有平均各图的比值。因为 24 张像素数相同，本实验的平均逐图 bpp 也等于总码率。

JPEG 与 DCTC 统计实际文件字节，包括各自码流头。Cheng 历史程序统计 `compress` 返回的实际熵编码字符串，包含主潜变量和超先验负载，没有统计独立文件容器头，也没有统计共享模型权重。因此，Cheng 表中结果应称为熵码流负载压缩比，不能声称已经包含完整自描述文件的全部开销。

质量指标在解码 RGB 与原图之间计算，范围为 0 到 1。每个档位的 PSNR 和 SSIM 均为 24 张逐图指标的算术平均。未用估计熵代替实际压缩字节。

14 完整 24 张的压缩结果

表 17 全部质量档的码率、质量和时间

方法	Q	bpp	PSNR / dB	SSIM	编码 / ms	解码 / ms
JPEG	30	0.659793	30.491473	0.86510658	0.5150	0.4991
JPEG	50	0.905521	32.173816	0.89965099	0.5461	0.5828
JPEG	70	1.238758	33.916748	0.92590776	0.5867	0.6814
JPEG	90	2.346323	38.033973	0.96335302	0.7168	0.9593
DCTC v1	30	0.711529	30.368194	0.86146591	42.4472	37.9828
DCTC v1	50	1.031225	32.027475	0.89682716	54.1809	50.7860
DCTC v1	70	1.455683	33.740348	0.92367104	68.1909	66.8513
DCTC v1	90	2.828743	37.676940	0.96201487	106.2965	116.5575
DCTC v2	30	0.995764	30.368194	0.86146591	7.1717	4.3162
DCTC v2	50	1.405468	32.027475	0.89682716	7.4865	4.3906
DCTC v2	70	1.944790	33.740348	0.92367104	7.9520	4.5039
DCTC v2	90	3.607437	37.676940	0.96201487	9.2594	4.7574
Cheng-A	1	0.119554	28.580356	0.76545180	2455.3542	6525.7653
Cheng-A	3	0.270888	31.340510	0.85727013	2225.8119	5775.7768
Cheng-A	6	0.805637	36.704702	0.94686304	2249.0610	5784.8805

表 18 全部质量档的两种压缩比和空间节省率

方法	Q	码流字节	RGB 压缩比	PNG 压缩比	RGB 节省 / %
JPEG	30	778,323	36.375068	19.778813	97.2509
JPEG	50	1,068,196	26.504080	14.411498	96.2270
JPEG	70	1,461,298	19.374249	10.534679	94.8385
JPEG	90	2,767,835	10.228772	5.561858	90.2237
DCTC v1	30	839,354	33.730169	18.340658	97.0353
DCTC v1	50	1,216,482	23.273301	12.654774	95.7032
DCTC v1	70	1,717,193	16.487111	8.964808	93.9347
DCTC v1	90	3,336,921	8.484334	4.613326	88.2136
DCTC v2	30	1,174,651	24.102097	13.105429	95.8510
DCTC v2	50	1,657,958	17.076158	9.285100	94.1439
DCTC v2	70	2,294,168	12.340662	6.710191	91.8967
DCTC v2	90	4,255,506	6.652923	3.617503	84.9690
Cheng-A	1	141,032	200.745590	109.154695	99.5019
Cheng-A	3	319,552	88.597637	48.174648	98.8713
Cheng-A	6	950,368	29.790094	16.198257	96.6432

Cheng-A Q6 的熵码流总量为 950368 字节，原始 RGB 压缩比为 29.790094，PNG 文件压缩比为 16.198257。平均 PSNR 为 36.704702 dB，SSIM 为 0.94686304。Q1 体积更小，但 PSNR 和 SSIM 也更低。

JPEG Q70 为 1.238758 bpp 和 33.916748 dB。Cheng Q6 在更低码率下得到更高的 PSNR 和 SSIM。两者的计时平台和容器开销不同，所以质量优势与部署速度分别解释，不合成单一性能分数。

DCTC v1 和 v2 的重建质量相同，但码流大小和时间不同。在 Q70，v2 编码为 7.952045 毫秒，解码为 4.503950 毫秒。v1 编码为 68.190934 毫秒，解码为 66.851325 毫秒。v2 更快，但原始 RGB 压缩比由 16.487 降至 12.341。自研实现仍未超过成熟 libjpeg 的综合表现。

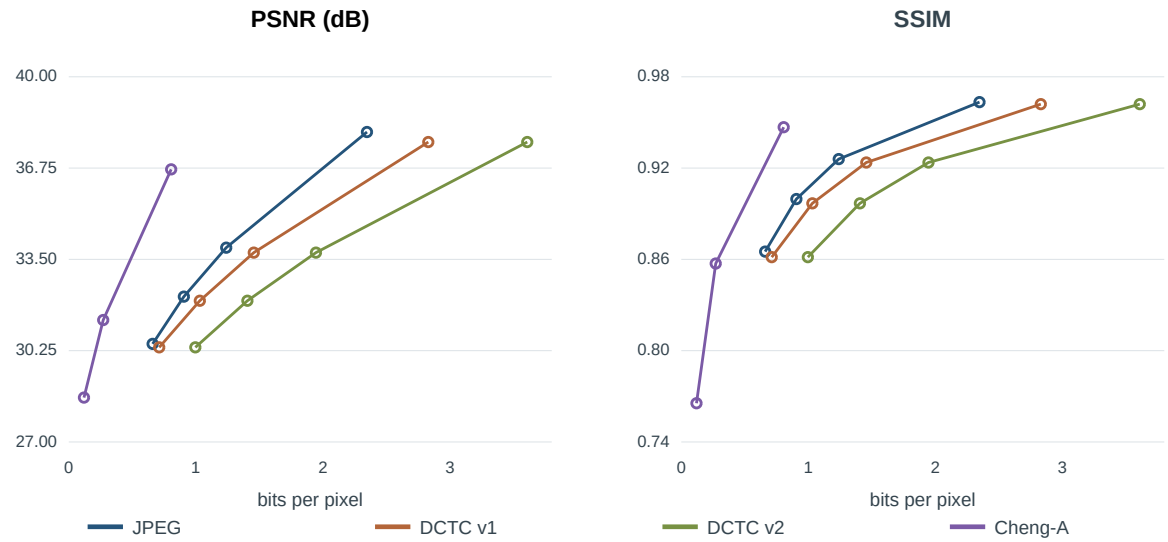

图 2 四种方法的实际率失真工作点。横轴为 bpp，左图为 PSNR，右图为 SSIM。曲线连接已测档位，不代表连续码率已经验证。Cheng 的横轴为熵码流负载口径。

JPEG 计时先预热 2 次，再执行 7 次，每图取中位数。DCTC 预热 1 次，重复 3 次。传统实验环境记录为 Python 3.12.14、NumPy 2.5.3 和 Pillow 12.3.0。学习模型使用 4090、Python 3.12.3 和 PyTorch 2.8.0 加 CUDA 12.8，预热 0 次、重复 1 次。

表中 Cheng 的编码约 2.2 秒，解码约 5.8 秒。其自回归熵处理较慢。传统计时不含质量指标和写盘，学习模型计时为实际压缩与解压调用。硬件与重复次数不同，因此这些是各自环境的历史耗时，未当作严格相同硬件的加速比。

15 压缩重建对比图

以下选择历史固定样例 01、04、13、23 和 24。每组列出原图、三个 Cheng 档位和传统方法的代表档位。图像从封存对比图中截取，没有运行新压缩，也没有人为锐化。展示分辨率低于原始图，细微块效应应结合原生解码图检查。

Kodak 样例 01

原图

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

各列保留原封存图的相同画面范围。质量档和码率不同，不能只按 Q 的数值比较算法。

Kodak 样例 04

原图

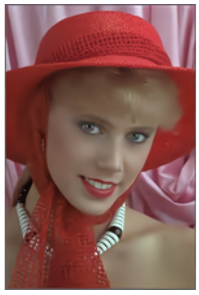

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

各列保留原封存图的相同画面范围。质量档和码率不同，不能只按 Q 的数值比较算法。

Kodak 样例 13

原图

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

各列保留原封存图的相同画面范围。质量档和码率不同，不能只按 Q 的数值比较算法。

Kodak 样例 23

原图

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

各列保留原封存图的相同画面范围。质量档和码率不同，不能只按 Q 的数值比较算法。

Kodak 样例 24

原图

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

各列保留原封存图的相同画面范围。质量档和码率不同，不能只按 Q 的数值比较算法。

16 压缩项目复现

16.1 代码和公开权重

自研编码器位于`src/dip_course/compression/dct_codec.py`。JPEG 和 DCTC 不需要训练权重。学习式实验使用 CompressAI 1.2.8 的 `cheng2020_anchor`, MSE 模型, 质量档 1、3、6。模型按该版本官方 zoo 接口下载。原实验未保存三个模型文件的完整 SHA256, 因此本报告不能补写原文件校验值。

新复现时应保存实际下载模型的哈希和版本。新增容器格式、Attention 模型或其他未完成改进不计入历史成绩。代码包固定到旧实验使用的已提交版本，避免把当前未提交的开发文件混入复现。

16.2 取得数据并检查

```
git clone https://github.com/MohamedBakrAli/Kodak-Lossless-True-Color-Image-Suite.git
    kodak_source
git -C kodak_source checkout --detach \
  dd2e1105fe8d9afe1120cd7e4c0e5e41f509a81b
mkdir -p data/compression/kodak
cp kodak_source/PhotoCD_PCD0992/*.png data/compression/kodak/
cd data/compression/kodak
shasum -a 256 -c ../../../manifests/compression/kodak.sha256
cd ../../..
```

需确认恰好 24 张 RGB PNG。若上游目录组织有变化，应按固定提交的清单放置, 不能额外加入缩略图或相似副本。

16.3 依次运行四种方法

下列命令适用于附件中的固定源码。旧文档曾出现 `stream-version` 和 `zlib-level` 写法, 当前固定入口实际使用 `stream-format` 和 `entropy-level`。本报告按已核对的参数名书写。

```
dip-compress-benchmark \
  --data-dir data/compression/kodak \
  --output-dir outputs/reproduce_compression/jpeg \
  --qualities 30 50 70 90 --subsampling 420 \
  --repeats 7 --warmup 2
dip-dct-benchmark \
  --data-dir data/compression/kodak \
  --output-dir outputs/reproduce_compression/dctc_v1 \
  --qualities 30 50 70 90 --subsampling 420 \
  --stream-format rle --entropy-level 9 --repeats 3 --warmup 1
dip-dct-benchmark \
  --data-dir data/compression/kodak \
  --output-dir outputs/reproduce_compression/dctc_v2 \
```

```
  --qualities 30 50 70 90 --subsampling 420 \
  --stream-format trimmed --entropy-level 1 --repeats 3 --warmup 1
python -m pip install -e '.[compression-ml]'
python -m pip install compressai==1.2.8
dip-learned-compression-benchmark \
  --data-dir data/compression/kodak \
  --output-dir outputs/reproduce_compression/cheng_anchor \
  --architecture cheng2020-anchor --qualities 1 3 6 --metric mse \
  --device cuda --repeats 1 --warmup 0 \
  --baseline-summary reports/assets/compression/jpeg_baseline/summary.json
```

JPEG 和 DCTC 每种生成 96 次图像编码评价，Cheng 生成 72 次。解码 PNG、逐图 CSV 和汇总 JSON 应保存在不同目录。它们与本报告的封存材料分开，避免新硬件的耗时覆盖历史记录。

后续可先统一硬件、容器头和模型体积统计，再做相同码率比较。DCTC 可继续优化系数打包和熵编码。学习模型可检查更快的上下文结构。以上是后续建议，本轮没有重新训练压缩模型。

第四部分 提交与复核

17 提交材料清单和复现边界

表 19 本次附件内容

文件	内容与用途
综合 PDF	三项方法、参数、全部汇总指标、限制和对比图
Overleaf LaTeX 工程	正文、生成表格、全部展示图片和图表，使用 XeLaTeX 编译
代码与指标包	固定代码快照、三个任务的逐图指标、环境说明、清单和复现入口
自训增强权重包	NAF、最终 LUT、两个成对对照和光度 v2，附文件大小、SHA256 和放置说明
原始增强 PNG	1000 张已完成本机备份，体积较大，未重复放入轻量代码包
需另外准备	SIED 及 GeoCorrection 原始数据、官方 SIED 模型、公开 UVDoc 和 OCR 模型、Cheng 模型
待恢复资料	原 PageMaskUNet 权重及 GeoCorrection 原始图像。保留原哈希与训练记录

只复核课程分数时，可先运行`reproduce_statistics.py`，核对 Canon1000 张逐图均值。几何和压缩的 CSV 也随包提供，本报告生成程序已按逐行数据复核其汇总。每种算法重新生成全部图像时，需要相应原始数据和模型。

固定源码来自 `beebb3454e99f039dfd98bc848aa7fafb9772f46`。新附的统计复核和独立增强复现脚本单独列出，不替换封存源文件。图像增强的新增独立入口只经过本机语法、参数和辅助检查，报告编写没有重新进行完整 CUDA 评价。

三项工作均保留传统方法和没有获益的实验。增强没有达到 30 dB，SSIM 略降。几何的外边界改善不能代替文字准确率。学习式压缩的较低码率也伴随更慢解码和共享模型成本。报告按这些实际限制说明成果，未扩大结论。

姓名和学号已填入封面。最终课程提交可将本报告、源码、指标和权重说明整理为 `-2025312132086-.zip`。本次只准备材料，不自动发送课程邮件。

参考文献

[1] Hai Jiang, Binhao Guan, Zhen Liu, et al. Learning to See in the Extremely Dark. ICCV, 2025, 7676–7685. https://github.com/JianghaiSCU/SIED.

[2] Liangyu Chen, Xiaojie Chu, Xiangyu Zhang, Jian Sun. Simple Baselines for Image Restoration. ECCV, 2022. https://arxiv.org/abs/2204.04676.

[3] Xiaojie Chu, Liangyu Chen, Chengpeng Chen, Xin Lu. Improving Image Restoration by Revisiting Global Information Aggregation. ECCV, 2022. https://arxiv.org/abs/2112.04491.

[4] Hui Zeng, Jianrui Cai, Lida Li, Zisheng Cao, Lei Zhang. Learning Image-adaptive 3D Lookup Tables for High Performance Photo Enhancement in Real-time. IEEE TPAMI. https://doi.org/10.1109/TPAMI.2020.3026740.

[5] Wontae Kim, Keuntek Lee, Nam Ik Cho. Lightweight and Fast Real-time Image Enhancement via Decomposition of the Spatial-aware Lookup Tables. ICCV, 2025, 11895–11905. https://github.com/WontaeaeKim/SVDLUT.

[6] Floor Verhoeven, Tanguy Magne, Olga Sorkine-Hornung. UVDoc: Neural Grid-based Document Unwarping. SIGGRAPH Asia, 2023. https://tanguymagne.com/publications/uvdoc/.

[7] Zhengxue Cheng, Heming Sun, Masaru Takeuchi, Jiro Katto. Learned Image Compression With Discretized Gaussian Mixture Likelihoods and Attention Modules. CVPR, 2020, 7939–7948. https://github.com/InterDigitalInc/CompressAI.

[8] CompressAI 预训练模型接口与官方实现。https://interdigitalinc.github.io/CompressAI/zoo.html.

[9] 数字图像处理课程课间实习课件，武汉大学，2026 年 9 月 30 日，第 8、9、14 页。