数字图像处理课程实习

综合实验报告

图像增强、几何校正、图像压缩

从传统算法到机器学习方法

姓名	韩勋同
学号	2025312132086
实验数据	SIED Canon 1000 张和 Sony 1000 张 GeoCorrection 200 张、Kodak 24 张
报告日期	2026 年 10 月 25 日
代码版本	Canon `beebb345`，Sony `ef3c0b46`

GitHub 代码仓库

https://github.com/xuntonghan/digital-image-proocess-work

两个相机各 1000 张的平均结果
Canon 的 PSNR 为 26.707356 dB，SSIM 为 0.843515758。
Sony 的 PSNR 为 26.721838 dB，SSIM 为 0.853275963。
两组均包含训练图，各自另列留出测试。

本报告汇总三项目已完成的实验。图像增强分别采用 Canon 和 Sony 各 1000 张结果，几何校正和压缩采用已保存的评价。

目录

报告说明 1

第一部分 项目一极暗图像增强 2

1 Canon 实验 2

2 Sony 实验 17

3 图像增强实验总结 24

第二部分 项目二几何校正 25

4 任务、数据和方法 25

5 几何与文字评价结果 26

6 几何校正对比图 28

7 几何校正复现入口 31

第三部分 项目三图像压缩 32

8 数据、编码方法和评价口径 32

9 完整 24 张的压缩结果 33

10 压缩重建对比图 34

11 压缩项目复现入口 40

第四部分 提交与复核 41

12 提交材料与使用说明 41

报告说明

本报告包含课程的三项实习。第一项从传统 ISP 和 U-Net 开始，使用 SIED 预训练模型恢复极暗 RAW，再增加 NAF 精修和自适应色彩表。第二项比较传统页面校正、UVDoc 曲面展平和 PageMaskUNet 自动页面分割。第三项比较 JPEG、自研 DCTC 和 Cheng2020 学习式压缩。

表 1 三个项目的主要结果和评价范围

项目	评价范围	主要结果
图像增强	Canon 全部 1000 张	PSNR 26.707356 dB, SSIM 0.843515758, LPIPS 0.324355896
图像增强	Sony 全部 1000 张	PSNR 26.721838 dB, SSIM 0.853275963, LPIPS 0.413931547
几何校正	自动方法隔离 22 张	分割 IoU 0.946106。校正后文本倾斜 7.103551 度，输入为 9.993837 度
图像压缩	Kodak 全部 24 张	Cheng-A Q6 为 0.805637 bpp，PSNR 36.704702 dB，SSIM 0.946863040，原始 RGB 压缩比 29.790094

图像增强的 1000 张包含训练图，不能解释为独立测试成绩。几何校正同时保存 200 张真值掩膜辅助实验和 22 张自动方法测试，二者分开列出。压缩比按实际码流计算，并注明学习模型的统计不含共享模型和容器头。

代码、逐图指标、模型附件和完整操作说明随提交包提供。

第一部分 项目一极暗图像增强

1 Canon 实验

Canon 实验使用 SIED 的 Canon_0.0001 数据，共 1000 对低光 RAW 和正常曝光参考图。实验先比较传统 ISP 与早期学习方法，再使用 Canon 专用 SIED、RAW 引导 NAF 精修和自适应色彩表。最终结果按全部 1000 张逐图计算 PSNR、SSIM 和 LPIPS，并单列训练、验证和留出测试。

1.1 数据读取和评价方法

1.1.1 RAW 数据和配对检查

Canon RAW 尺寸为 3840 乘 2160。文件没有图像头，数据类型为无符号 16 位整数。每个 RAW 文件应为 16,588,800 字节。黑电平为 512，白电平为 16383。图像按下式归一化，并将结果限制在 0 到 1 之间。

$$r = \operatorname{clip}\left(\frac{r_{\mathrm{raw}} - 512}{16383 - 512}, 0, 1\right). \tag{1}$$

之后按 RGGB 排列打包为四通道。四通道分别保存 R、R 行中的 G、B 和 B 行中的 G。参考图为正常曝光 RGB 图像。输入和参考图的配对关系由清单文件确定，不用文件遍历顺序猜测。

1000 对图像的配对和尺寸检查全部通过，没有重复或缺失。

1.1.2 训练、验证和测试划分

采用 SIED 作者仓库的固定测试划分 [1]。官方训练部分为 924 张，官方测试部分为 76 张。在 924 张中，以种子 20260930 分出 92 张验证图，剩余 832 张用于附加模型训练。

表 2 本轮固定数据划分

用途	数量	清单文件
训练	832	`manifests/enhancement/canon_train.txt`
验证	92	`manifests/enhancement/canon_val.txt`
测试	76	`manifests/enhancement/canon_test.txt`
总体	1000	`manifests/source/canon_all.txt`

三个划分互不重复。官方模型预训练见过其中 924 张，92 张验证图只用于选择新增分支。1000 张总体含训练图，不能视为独立测试。最终模型按验证结果冻结，再评价全

部 1000 张。

1.1.3 主指标的计算

所有主指标均来自保存为 8 位 PNG 之前的浮点预测。预测和参考图采用 0 到 1 的 RGB 数值，并保持 3840 乘 2160 的原生尺寸。

对第 i 张图像，均方误差和 PSNR 定义为

$$\mathrm{MSE}_i = \frac{1}{3HW} \sum_{h,w,c} (x_{i,h,w,c} - y_{i,h,w,c})^2, \tag{2}$$

$$\mathrm{PSNR}_i = -10 \log_{10}(\mathrm{MSE}_i). \tag{3}$$

1000 张平均 PSNR 按下式计算。SSIM 和 LPIPS 也先逐图计算，再取图像均值。

$$\overline{\mathrm{PSNR}} = \frac{1}{1000} \sum_{i=1}^{1000} \mathrm{PSNR}_i. \tag{4}$$

三个部分按 832/1000、92/1000 和 76/1000 加权，等于 1000 张逐图均值。

SSIM 调用 scikit-image 0.26.0 中的 `structural_similarity`，设置 `data_range=1.0` 和 `channel_axis=-1`。没有额外裁边，也没有改成单独的亮度通道。其余参数使用该版本默认值。

LPIPS 使用 AlexNet 版本。RGB 先由 0 到 1 映射到负 1 到 1，然后输入固定评价网络。LPIPS 越低，表示该评价模型判断的感知差异越小。

1.1.4 颜色指标和异常处理

补充指标包括平均 CIEDE2000 色差、逐图色差 P95 的均值、亮度 MAE、饱和度 MAE 和色相误差。颜色指标在最长边为 960 像素的副本上计算。缩放使用双线性插值和抗混叠。它们的分辨率与原生 PSNR 和 SSIM 不同。

色相采用环形距离。只在参考图饱和度至少 0.1、亮度至少 0.05 的像素上计算色相误差，再换算为度。没有满足条件的像素时，按既定实现记为 0。程序要求 1000 个编号唯一、划分正确、全部指标有限。异常值会导致检查失败，不会被静默删除。

1.2 算法设计和训练设置

1.2.1 传统方法和早期学习方法

传统 ISP 依次完成黑电平校正、去马赛克、灰世界白平衡、自动曝光、Gamma 变换和数值限制。Canon 正式传统基线使用 Gamma 2.0、亮度第 98 百分位、目标亮度 0.9 和白平衡指数 1.0。逐图曝光和白平衡只读取低光输入，不读取参考图。

早期 Residual U-Net 接收四通道 RAW。网络末端输出 12 通道，再用 PixelShuffle 恢复三通道全分辨率图像。模型约有 1789 万参数。训练 RAW 块为 256 乘 256，对应

RGB 块为 512 乘 512。批量大小为 4，优化器为 AdamW，初始学习率为 10^{-4}。主损失包含 L1、SSIM 和色度误差。历史 Canon 最优权重来自第 3000 步。该结果只作为早期 76 张测试记录，不写入 1000 张主表。

1.2.2 官方 SIED 和光度精修

SIED 使用作者发布的预训练权重 [1]。恢复过程只输入低光 RAW。自适应照明校正模块先处理曝光，再由扩散模型恢复 RGB 信息。当前设置为 20 步 DDIM 和三次独立采样平均。第 i 张原划分内图像、第 j 次采样的种子为

$$s_{i,j} = 3407 + i + 1000003j, \qquad j = 0, 1, 2. \tag{5}$$

索引在各自划分内部计算，不改为 1000 张的总索引。固定种子帮助保持同一设置，但跨 GPU 和 CUDA 版本仍可能有数值差异。

全场景光度精修根据低分辨率整图预测曝光、Gamma、白平衡、颜色矩阵和低频照度。初始变换为恒等变换，参数变化受限。v2 版本使用批量大小 8、学习率 2×10^{-5}、BF16 和 1500 步训练。它只作为后续模型的起点和历史对照。

1.2.3 RAW 引导 NAF 精修

结构分支借鉴 NAFNet 的设计 [2]。RGB 和上采样后的四通道 RAW 组成七通道输入。网络宽度为 48，编码块数为 2、2、4，中间为 6 块，解码块数为 2、2、2。残差最大幅度由 $0.35\tanh(\cdot)$ 限制。RAW 增益使用整图均值，目标均值 0.1，最大增益 4096。输出头从零初始化。

前期共运行五个阶段。NAF 阶段使用 AdamW、余弦学习率、EMA 0.999、批量大小 1 和 FP16。各阶段的主要参数见表3。缩略图验证、快速原生验证和完整原生验证分别保存，不混成一个成绩。

表 3 NAF 五阶段的主要设置

阶段	实际步数	学习率	训练和评价设置
阶段一	20000	2×10^{-4}	长边 768 缩略图训练，完整 92 张原生复核
阶段二	2500	5×10^{-5}	在线原生预测，512 RGB 块，冻结光度分支
阶段三	2000	2×10^{-5}	继续微调，使用 MSE 主导目标
阶段四	20000	2×10^{-5}	原生盲预测缓存，512 块，全场景 RAW 均值
阶段五	3000	2×10^{-5}	整图光度冻结，512 块，原生验证后早停

阶段四被选为冻结基线。它训练完成后的最佳权重仍接近训练起点。阶段五也没有选中新增训练步的权重。增加训练次数没有带来持续改善，报告保留这一结果。

1.2.4 TLC 局部聚合对照

TLC 针对训练小块和整图推理的全局统计差异 [3]。本轮只转换 NAF 结构分支，窗口为 512，积分图使用 FP32。固定 12 张验证图的 PSNR 由 26.952234 降为 26.853515 dB。该设置未通过门槛，因此没有继续进行 92 张完整验证，也没有用于最终模型。

1.2.5 自适应三维色彩表

自适应色彩表参考图像自适应 3DLUT 的方法 [4]。本项目使用独立的 PyTorch 实现，没有使用 FiveK 权重和旧 CUDA 扩展。表格每轴有 17 个格点，使用 3 个基底，RGB 残差上限为 0.12。小型 CNN 根据整图内容给出基底权重。附加模型共有 63,324 个参数。

系数先根据最长边 512 的整图上下文计算。控制器再读取最长边 128 的内容。所有原生图像块查询同一张色彩表，不在每个小块上重新估计色调。色彩表从恒等变换开始，官方 SIED 和 NAF 权重保持不变。

训练输入为 832 张训练图的 FP32 成对缩略图，尺寸 512 乘 288。批量大小为 16。使用 FP32、fused AdamW、初始学习率 3×10^{-4}、权重衰减 10^{-4} 和梯度范数限制 1。余弦学习率最低为 10^{-5}。损失为逐图 RGB log-MSE 加 0.1 倍平滑和单调约束。训练上限 1500 步，每 250 步检查相同的 12 张原生验证图。训练含周期验证的时间上限为 45 分钟。

候选相对当前已保存权重至少再提高 0.01 dB 时才更新。因此，最终保存第 1250 步。第 1500 步的快速验证略高，但增幅不足更新门槛。完整 92 张成绩对应第 1250 步权重。

1.2.6 低秩色彩表和成对实验

本轮也参考 SVDLUT 的分解思想 [5]，实现 RG、RB 和 GB 三个二维表的低秩表示。rank 设为 4。低秩附加模型共有 22,779 个参数，比 global3d 少约 64%。它仍会重建小型三维表，再使用同一种插值查询。它没有包含论文中的空间或双边分支。

global3d 和低秩模型采用相同控制器初值、私有批次随机序列、精度、优化器、损失和 1000 步上限。每个模型的训练含周期验证最多 15 分钟。完整 92 张验证在训练结束后执行。两个模型都通过候选门槛。低秩模型的质量稍低，完整 1000 次训练更新的平均步时也更长。

1.3 实验结果与分析

1.3.1 验证门槛和冻结顺序

候选需要在原生验证图上满足以下条件。

1. 平均 PSNR 比冻结基线至少提高 0.02 dB。
2. SSIM 下降不超过 0.002。

3. 各项颜色误差和 LPIPS 的增幅不超过 2%。

4. 完整 92 张记录、权重和文件哈希一致。

通过快速验证后才执行完整 92 张验证。合格候选中选择 PSNR 最高者。只有 PSNR 精确相同时，才比较 SSIM。

表 4 完整 92 张验证的候选比较

方法	所选步 / 实际步	附加参数量	PSNR / dB	SSIM
冻结基线	不适用	0	26.636931	0.85627188
自适应 3DLUT	1250 / 1500	63,324	26.842980	0.85626056
global3d 对照	750 / 1000	63,324	26.799789	0.85630565
低秩 rank4	1000 / 1000	22,779	26.782930	0.85619018

完整 92 张验证后选择第一组第 1250 步 LUT，随后冻结模型并评价 1000 张。测试分数不参与选择。

表 5 完整 92 张验证的补充指标

指标	冻结基线	自适应 3DLUT	global3d 对照	低秩 rank4
LPIPS	0.31336739	0.31313677	0.31315882	0.31359197
平均色差	4.496330	4.473077	4.475649	4.493532
色差 P95 的图像均值	7.831748	7.851426	7.847209	7.852467
亮度 MAE	4.455134	4.419811	4.424134	4.442064
饱和度 MAE	0.03374167	0.03310769	0.03323075	0.03348335
色相误差 / 度	11.346907	11.199809	11.206710	11.268015

第一组训练 1500 步，第二组每个模型训练 1000 步，批次和调度也有差别。因此，第一组和第二组的分数差不能单独归于显存常驻。成对实验内的 global3d 和低秩对照更适合分析参数化的影响。

1.3.2 完整 1000 张的提交成绩

最终 1000 张平均 PSNR 为 26.707356 dB。平均 SSIM 为 0.843515758，平均 LPIPS 为 0.324355896。三个结果均由 1000 个逐图指标取算术平均得到。

表 6 完整 1000 张的基线和最终结果

指标	基线 1000 张	最终 1000 张	最终值减基线
PSNR / dB	26.554490	26.707356	+0.152867
SSIM	0.84355310	0.84351576	-0.00003734
LPIPS	0.32444085	0.32435590	-0.00008495
平均色差	4.595405	4.575388	-0.020018
色差 P95 的图像均值	8.165957	8.169354	+0.003397
亮度 MAE	4.458091	4.433654	-0.024438
饱和度 MAE	0.03768485	0.03725874	-0.00042611
色相误差 / 度	11.926284	11.887847	-0.038438

PSNR 提高 0.152867 dB。SSIM 下降 0.00003734。平均色差、亮度、饱和度、色相和 LPIPS 略有改善，色差 P95 略有上升。该结果没有达到 30 dB。

逐图 PSNR 有 524 张提高、476 张下降。变化的中位数为 0.105085 dB，最小值为负 1.752339 dB，最大值为 4.137213 dB。SSIM 有 497 张提高、503 张下降。所有图像都计入总体，没有筛除下降样例。

1.3.3 三个部分的结果

表 7 最终模型的分项结果

指标	训练 832 张	验证 92 张	测试 76 张
PSNR / dB	27.011915	26.842980	23.209062
SSIM	0.84743960	0.85626056	0.78513208
LPIPS	0.32044560	0.31313677	0.38074438
平均色差	4.362747	4.473077	7.027098
色差 P95 的图像均值	7.781651	7.851426	12.798538
亮度 MAE	4.249130	4.419811	6.470454
饱和度 MAE	0.03495672	0.03310769	0.06748473
色相误差 / 度	10.778889	11.199809	24.860905

训练部分平均 PSNR 为 27.011915 dB。验证部分为 26.842980 dB。

留出测试为 23.209062 dB，比基线低 0.086934 dB，SSIM 低 0.00067038。测试中 22 张 PSNR 提高，54 张下降。

训练和验证中的收益未转化为测试收益，因此同时报告总体和各划分结果。

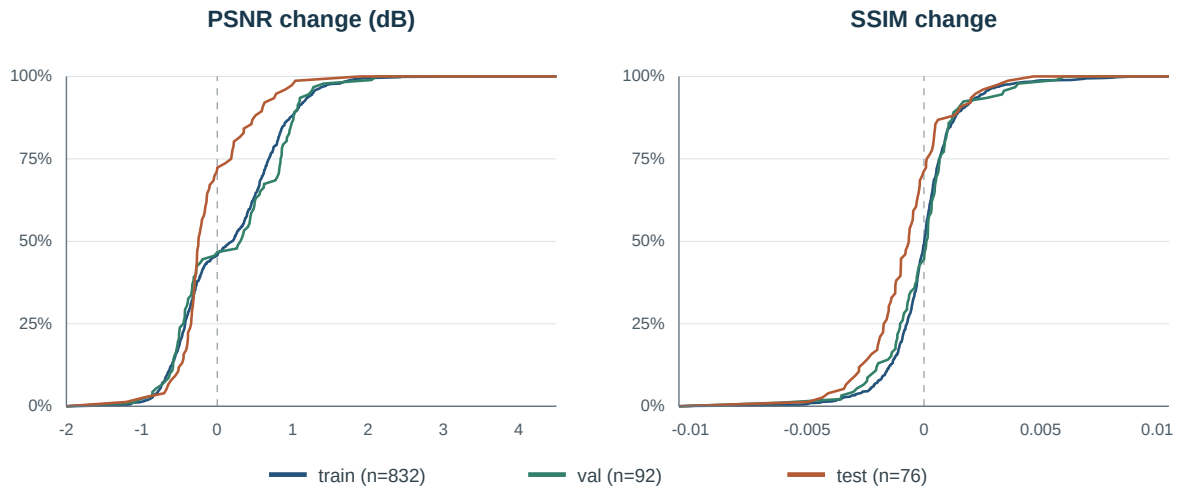

图 1 逐图指标变化的累计分布。横轴为最终值减基线值，纵轴为各部分内部的图像占比。零线左侧表示下降。PSNR 和 SSIM 越大越好。三条曲线分别使用 832、92 和 76 张图像。

新最终 1000 张全部在 RTX4090 上评价。历史基线的训练和验证结果来自 4090，76 张测试复用 4080 SUPER vGPU 的封存记录。硬件不同是比较的限制之一。最终 92 张验证重放与选择模型前的 92 张结果逐图一致，全部 8 项指标的最大绝对差为 0。

1.3.4 早期 76 张 Canon 测试记录

表 8 早期 Canon 测试结果，数量均为 76 张

方法	PSNR / dB	SSIM	LPIPS
自动传统 ISP	13.739991	0.13553439	0.91636975
Residual U-Net	16.123392	0.62203754	0.63799402
官方 SIED 三次平均	22.169954	0.78170272	未计算
SIED 和光度精修 v1	22.905984	0.78611727	未计算
SIED 和光度精修 v2	22.997996	0.78676497	未计算
阶段四 NAF 基线	23.295996	0.78580246	0.38010382
本轮最终色彩表	23.209062	0.78513208	0.38074438

历史设置略有差异，未计算的 LPIPS 按表标注。这些分数不替代 1000 张成绩。

1.4 效果图与分析

12 组样例均来自 76 张测试图。前 6 组按历史固定顺序，后 6 组从其余图像中按 PSNR 变化排序取 6 个等距位置。效果图包含整图和相同区域的细节，保留提高与下降样例。它们不参与模型选择或总体统计。

RAW 和 ISP 列从封存图截取。RAW 预览使用曝光 1 和 Gamma 2.2。ISP 示意使用 Gamma 2.2、分位数 99 和目标 0.9，与正式传统基线参数不同。基线与最终图来自原生 PNG，参考来自原 JPG。展示只做等比例缩放，不改变色调。局部区域统一为 $(1280, 720)$ 至 $(2560, 1440)$。分数读取原生浮点记录。

样例 1，图像 6

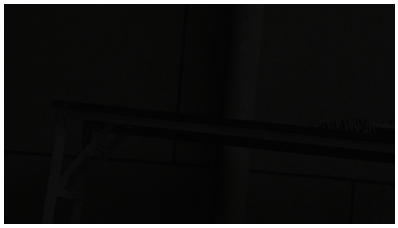

低光 RAW 预览

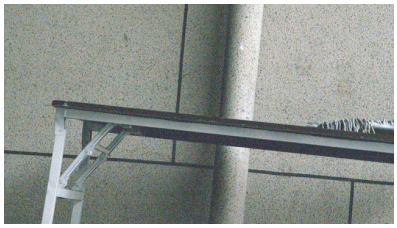

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 26.7293 变为 27.0823 dB。
SSIM 由 0.725678 变为 0.725140。
LPIPS 由 0.347511 变为 0.348731。

本例 PSNR 提高 0.3530 dB。

样例 2，图像 8

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 28.4444 变为 28.4371 dB。
SSIM 由 0.837431 变为 0.840545。
LPIPS 由 0.306639 变为 0.305889。

本例 PSNR 下降 0.0073 dB。

样例 3，图像 10

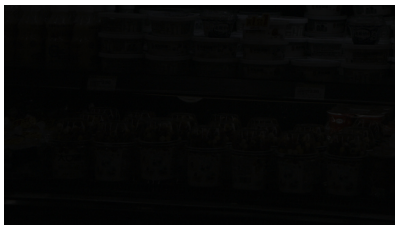

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 29.3118 变为 29.2635 dB。
SSIM 由 0.861883 变为 0.861425。
LPIPS 由 0.299394 变为 0.298354。

本例 PSNR 下降 0.0482 dB。

样例 4，图像 14

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 28.3187 变为 28.5358 dB。
SSIM 由 0.887971 变为 0.888086。
LPIPS 由 0.265167 变为 0.263989。

本例 PSNR 提高 0.2171 dB。

样例 5，图像 21

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 27.1846 变为 27.7754 dB。
SSIM 由 0.917327 变为 0.917800。
LPIPS 由 0.122112 变为 0.122196。

本例 PSNR 提高 0.5909 dB。

样例 6，图像 28

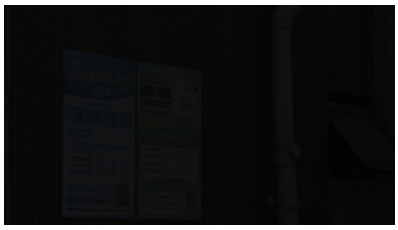

低光 RAW 预览

传统 ISP 示意

参考图

冻结基线

最终 LUT 方案

PSNR 由 28.5727 变为 29.4779 dB。
SSIM 由 0.922125 变为 0.922508。
LPIPS 由 0.213063 变为 0.212844。

本例 PSNR 提高 0.9052 dB。

样例 7，图像 127

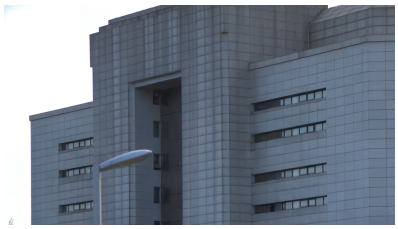
冻结基线，整幅图像

最终 LUT 方案，整幅图像

参考图，整幅图像

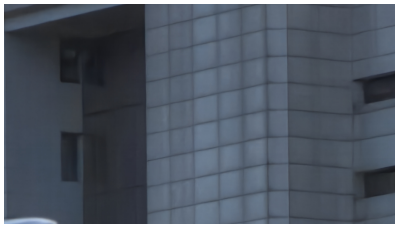
冻结基线，相同中心区域

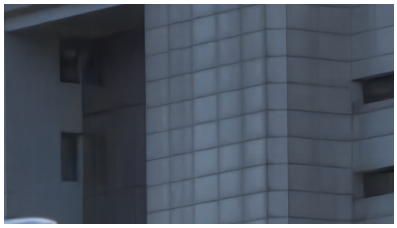
最终 LUT 方案，相同中心区域

参考图，相同中心区域

PSNR 由 27.4594 变为 26.2552 dB。SSIM 由 0.924177 变为 0.922291。LPIPS 由 0.302568 变为 0.303303。

本例 PSNR 下降 1.2042 dB。

样例 8，图像 57

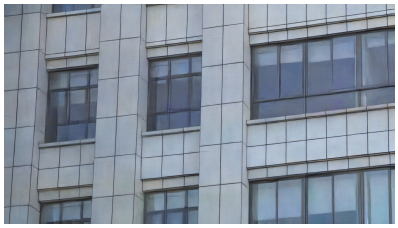
冻结基线，整幅图像

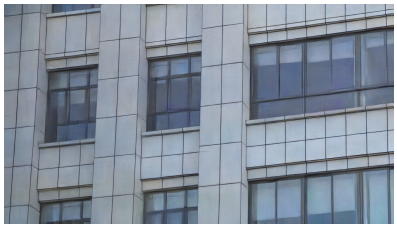
最终 LUT 方案，整幅图像

参考图，整幅图像

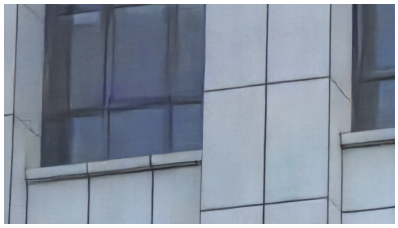
冻结基线，相同中心区域

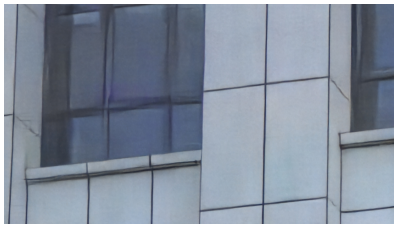
最终 LUT 方案，相同中心区域

参考图，相同中心区域

PSNR 由 17.7879 变为 17.3965 dB。SSIM 由 0.846605 变为 0.844626。LPIPS 由 0.268805 变为 0.270943。

本例 PSNR 下降 0.3914 dB。

样例 9，图像 671

冻结基线，整幅图像

最终 LUT 方案，整幅图像

参考图，整幅图像

冻结基线，相同中心区域

最终 LUT 方案，相同中心区域

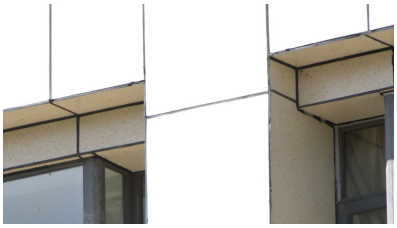

参考图，相同中心区域

PSNR 由 17.1841 变为 16.8853 dB。SSIM 由 0.853089 变为 0.851863。LPIPS 由 0.266117 变为 0.265603。

本例 PSNR 下降 0.2988 dB。

样例 10，图像 904

冻结基线，整幅图像

最终 LUT 方案，整幅图像

参考图，整幅图像

冻结基线，相同中心区域

最终 LUT 方案，相同中心区域

参考图，相同中心区域

PSNR 由 20.3978 变为 20.1891 dB。SSIM 由 0.693136 变为 0.692489。LPIPS 由 0.498721 变为 0.500044。

本例 PSNR 下降 0.2086 dB。

样例 11，图像 680

冻结基线，整幅图像

最终 LUT 方案，整幅图像

参考图，整幅图像

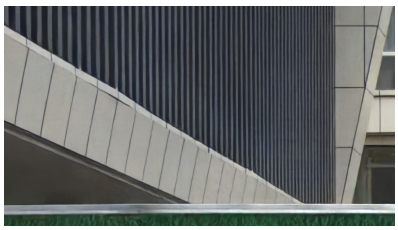

冻结基线，相同中心区域

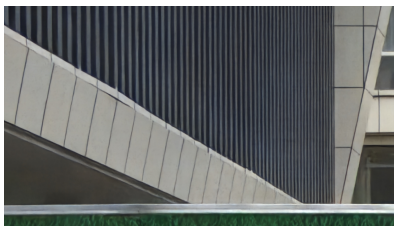

最终 LUT 方案，相同中心区域

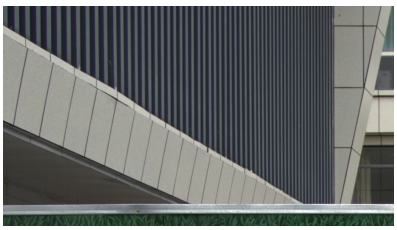

参考图，相同中心区域

PSNR 由 29.8102 变为 30.0038 dB。SSIM 由 0.827411 变为 0.827499。LPIPS 由 0.274839 变为 0.274941。

本例 PSNR 提高 0.1936 dB。

样例 12，图像 141

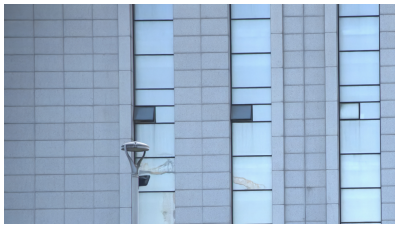

冻结基线，整幅图像

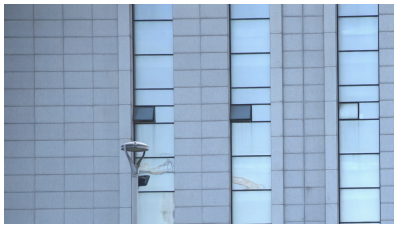

最终 LUT 方案，整幅图像

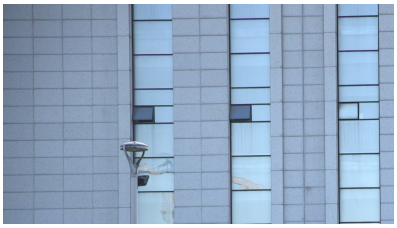

参考图，整幅图像

冻结基线，相同中心区域

最终 LUT 方案，相同中心区域

参考图，相同中心区域

PSNR 由 29.3229 变为 31.2216 dB。SSIM 由 0.835638 变为 0.835881。LPIPS 由 0.299020 变为 0.299288。

本例 PSNR 提高 1.8988 dB。

1.5 速度、资源和验证

924 张训练和验证图的盲扩散基础输出保存为原样 FP32 缓存。后续候选复用缓存，避免重复执行扩散。约 86 GiB 基础缓存和约 3 GiB 训练缩略对可以重新生成。本机没有下载这些大缓存，但保留了逐图哈希、种子和生成代码。

832 张 FP32 训练对常驻 GPU 时占 2,944,401,408 字节。一次预加载用时 2.448222 秒。短测使用 4 次预热和 16 次计时更新，批量大小 16。

表 9 真实训练批次短测

数据方式和模型	平均秒/步	附加参数量
pinned DataLoader 和 global3d	0.03469200	63,324
显存常驻和 global3d	0.01299559	63,324
显存常驻和低秩 rank4	0.01302303	22,779

同一个 global3d 模型的短批次吞吐约为原来的 2.669521 倍。首个预测完全一致，20 次更新后参数最大绝对差为 1.0766×10^{-6}。这个测量不含完整原生验证和预加载摊销，不能说明整次训练都提高相同比例。

完整 1000 次训练更新的平均步时为 global3d 0.01239057 秒、低秩 0.01373014 秒。低秩约慢 10.81%。包含周期验证的阶段分别用时 251.85396 秒和 252.78675 秒，均不含之后的完整 92 张验证。参数更少没有在本轮带来速度优势。

NAF 的另一组合成数据短测中，channels-last、FP16 和 fused AdamW 的吞吐为原来的 1.168 倍。单独使用 channels-last 更慢。该结果与色彩表短测来自不同模型，不能相乘。

训练与验证使用缓存，测试重新执行扩散，混合计时不代表统一的端到端单图速度。

176 项回归和 20 项最终评价检查通过。1000 张逐图指标、模型哈希和原生 PNG 尺寸均已核验。

1.6 代码、权重和复现入口

代码仓库和完整提交资料分别位于以下地址。

https://github.com/xuntonghan/digital-image-proocess-work

https://github.com/xuntonghan/digital-image-proocess-work/releases

核心推理源码固定到 `beebb3454e99f039dfd98bc848aa7fafb9772f46`。代码包另附统计复核和独立推理入口。1000 行 CSV 保留原始精度、编号、划分、种子及图像哈希。

1.6.1 模型与环境

最终增强使用官方 SIED、阶段四 NAF 和第 1250 步 LUT。自训权重包还保留两个色彩表对照及光度 v2。官方 SIED 从作者发布地址另行获取。

表 10 模型文件大小与完整 SHA256

模型	字节	SHA256
NAF 阶段四	36,230,265	337acc11705e8ae1f170d22263161b210a0ed0d4272a647db4e82ccbb611f2d8
最终 LUT	317,445	2cfd72ec81addd4a091ea199c613c4bc47e27e562a098971db7302510a1db609
全表对照	316,869	47580a832b66a43bcedf6276678f11a3a1969b47d15c9e2568bad1238f472323
低秩对照	154,946	7ab0c534f3b353adf919d35529679d1d27874a98d5bbdf0b9697c6f7cbfebda9
光度 v2	193,785	0428cdb082979ed960cfd5925a78ae558a635dfd8eaf0f783023272f65b27afa
官方 SIED	2,610,348,582	40014f1f71dfdcd9a8969074097f675a54d2598aec26b183c0874bfcd5c26238

评价环境为 Python 3.12.3、PyTorch 2.8.0 加 CUDA 12.8、torchvision 0.23.0、NumPy 2.3.2、Pillow 11.3.0、scikit-image 0.26.0 及 LPIPS 0.1.4。原生 FP16 推理使用 RTX4090。

1.6.2 复现顺序

1. 解压代码与指标包，按附件完整复现命令.txt 安装依赖并准备原始数据。
2. 解压自训权重到`submission_weights/`，核对 SHA256。官方 SIED 代码固定到`fb7af94ac831e91c647415bf1ca0b1a75931833a`。
3. 先运行下列命令复核 1000 张均值。该步骤只需要 Python 标准库。

```
python3 reproduce_statistics.py
```

完整推理使用`cloud/reproduce_sied_submission.py`，参数和操作命令见附件。先用`--limit-new 3`检查 3 张训练图，再去掉该参数继续至 1000 张。程序读取同一组固定权重，预测后才读取参考图，结果写入新目录。

独立入口通过本机语法、参数和固定资料检查，未在报告编写时再次执行 CUDA 全量评价。它重新计算扩散输出，不依赖旧 FP32 缓存，跨硬件浮点结果可能存在末位差异。

2 Sony 实验

Sony 实验使用 SIED 的 Sony_0.001 数据，共 1000 对低光 RAW 和正常曝光参考图。模型采用 Sony 专用 SIED 和 Sony 专用自适应色彩表。独立完成数据检查、训练、模型选择和全部 1000 张评价。

Sony 评价使用 RTX4090 24GB，Python 3.12、PyTorch 2.8.0 与 CUDA 12.8。NumPy 为 2.3.2，Pillow 为 11.3.0，scikit-image 为 0.26.0，LPIPS 为 0.1.4。

2.1 数据与参数

原始划分为 822 张训练、91 张验证和 87 张测试。2000 个配对文件共 18,653,873,890 字节，与原始审计一致。RAW 尺寸为 3840 乘 2160，黑电平为 512，白电平为 16383，按 RGGB 打包为四通道。正式 PSNR 和 SSIM 在原生 3840 乘 2160 浮点 RGB 上计算，之后才保存 PNG。全部 1000 张逐图取算术平均。

官方 Sony 模型见过 913 张训练和验证图。因此 1000 张总体包含训练数据，91 张验证只用于选择新增模型，87 张留出测试另列。测试参考图只在预测后用于评分。

使用 FP16、20 步 DDIM 和三次独立预测平均。划分内第 i 张图像、第 j 次采样的种子为 $3407 + i + 1000003j$，$j = 0, 1, 2$。PSNR、SSIM、LPIPS 和颜色指标沿用 Canon 实验中的计算定义。新增色彩表有 63,324 个参数，17 个格点、3 个基底和 0.12 残差上限。整图 512 上下文与训练保持一致。原生查询每块 256 行，共用整图系数。

训练只用 822 张的 512 乘 288 FP32 对。批量 16，fused AdamW，学习率 3×10^{-4}，权重衰减 0，逐图 log-MSE 加 0.1 倍平滑和单调约束。初始模型为恒等变换。完成 1000 步，每 250 步检查固定 12 张原生验证图，之后通过完整 91 张验证。

候选 PSNR 须至少提高 0.02 dB，SSIM 下降不超过 0.002，各项颜色误差和 LPIPS 增加不超过 2%。模型冻结后才开始留出测试评分。

2.2 ICCV 方法对照与执行效率

继续参考 ICCV 2025 的 GT-Mean Loss[6]。在原 1000 步色彩表上做两个各 250 步的对照。两组使用同一初值和批次序列，批量 16、FP32、学习率 3×10^{-5}。对照组延续 log-MSE，论文方法组再加 5 倍 GT-Mean L1，$\sigma = 0.1$。GT 均值只出现在训练损失中，推理不读取参考图。这是损失方法的独立对照，没有重新训练整篇论文网络。

表 11 Sony 追加训练的固定 12 张原生验证

方法	PSNR / dB	SSIM	是否采用
原 1000 步色彩表	27.491202	0.831919953	原方案
追加 250 步对照	27.495772	0.831932972	未采用
追加 250 步 GT-Mean	27.495601	0.831933945	未采用

两个分支的快速验证收益都低于预设 0.02 dB 门槛，因此停止追加训练，保留已通过完整 91 张验证的原方案。没有扩大为新一轮全量训练，也没有用测试结果挑选模型。

两组各 250 步的训练更新分别用时 2.057 秒和 2.010 秒。该时间不含数据预载和原生验证，不能作为整次实验用时。

评价采用单 GPU 盲预测和 4 个有上限的 CPU 指标与写图线程。固定 4 张训练图的串行用时 39.685 秒，并行用时 13.959 秒，短测吞吐为原来的 2.843 倍。PNG 哈希和全部 8 项浮点指标一致。这是执行短测，没有降低分辨率、精度、采样次数或评价标准。

训练与验证采用原样 FP32 缓存，训练缓存上限 40 GiB。最终续算沿用同一模型已完成的 120 张，另外的图按原清单继续。87 张测试重新执行盲扩散。缓存和重新预测的混合计时不代表统一的单图端到端速度。

2.3 实验结果与分析

表 12 Sony 全部 1000 张的逐图算术均值

方案	PSNR / dB	SSIM	LPIPS
官方 Sony SIED	26.293514	0.852384071	0.415136708
最终 Sony 方案	26.721838	0.853275963	0.413931547

PSNR 相对官方模型变化 +0.428325 dB，SSIM 变化 +0.000891891。PSNR 有 692 张提高、308 张下降，变化中位数为 +0.619618 dB。全部图像都纳入均值。

表 13 Sony 最终方案的各划分结果

划分	数量	PSNR / dB	SSIM	LPIPS
训练	822	26.864294	0.855436357	0.415472312
验证	91	27.000134	0.853357347	0.397774787
留出测试	87	25.084787	0.832778838	0.416273572

87 张留出测试的官方 PSNR 为 24.729609 dB，最终为 25.084787 dB。SSIM 由 0.831428029 变为 0.832778838。两项留出测试主指标均提高。

表 14 Sony 全部 1000 张的颜色指标

指标	官方 Sony	最终方案
平均色差	5.15293871	4.93803198
逐图色差 P95 均值	9.26530563	9.03403853
亮度 MAE	4.57738172	4.25040546
饱和度 MAE	0.05452359	0.05427867
色相误差 / 度	18.04123387	17.91118229

表 15 Sony 最终方案各划分的颜色指标

划分	平均色差	色差 P95 均值	亮度 MAE	饱和度 MAE	色相误差度
训练	4.857474	8.842668	4.215061	0.052172	17.334434
验证	4.691610	8.425323	3.999269	0.052005	17.469849
留出测试	5.956917	11.478861	4.847037	0.076559	23.822088

2.3.1 早期方法对照

表 16 Sony 早期方法的 87 张测试结果

方法	PSNR / dB	SSIM	LPIPS
自动传统 ISP	14.298588	0.16415948	0.86546771
Residual U-Net	17.051680	0.63324569	0.69637270

Sony 传统设置为 Gamma 1.8、分位数 99、目标 0.9 和白平衡指数 1.0。上表来自已保存 CUDA 摘要，与本机 MPS 复现的末位数值略有差别。它仍只包含 87 张，不能写成 Sony 全部 1000 张。

2.4 代码和权重

原始官方代码固定在前述 SIED 提交。Sony 官方模型为`sony_0.001.pt`，大小 2,610,974,590 字节，需从作者仓库下载并核对下列 SHA256。

```
7379cdec9401b92ea28b26568a5b33f7e72be06a0e7c12d1c76f76e3499f693d
```

新增 Sony 权重随自训增强权重包提供，名称为`sony_color_lut_selected.pt`。其 SHA256 为

13bce17147874633d9b7618d75f8f6b201825d04dab43a89a9a5181ac36c5f01

Sony 实验源码版本为ef3c0b46b86177890dde9def4c581215dd9f4e2e。原冻结推理和指标源码保持原字节，执行器另行保存源码哈希与原生等价证明。sony_report_data.json 记录模型、展示图、逐图指标和来源。

只复算封存指标时不需要 GPU。

```
python3 cloud/verify_sony1000.py
```

从 RAW 重跑使用cloud/reproduce_sony_submission.py，不依赖 40 GiB 训练缓存。先检查 3 张训练图，再在新目录完成全部 1000 张。完整参数、数据获取和权重检查命令随包提供。正式输出保留 1000 行 CSV、种子、划分、模型绑定和 PNG 哈希。

2.5 效果图与分析

椅子与门窗样例中，最终方案的亮度更接近参考图。车辆和文字样例可用于比较颜色、边缘和文字区域。局部图使用相同范围，便于检查色彩变化和细节保留。所有分数仍来自整幅原生浮点预测。

对比图说明 六组样例取原测试清单前 6 张。RAW 预览采用曝光 1 和 Gamma 2.2, ISP 采用 Gamma 1.8、99 百分位和目标 0.9。模型图只作等比例缩放，局部固定为 $(1280, 720)$ 至 $(2560, 1440)$。

Sony 样例 1，图像 6

低光 RAW 预览

传统 ISP 示意

参考图

官方 Sony

最终 Sony

PSNR 由 21.6981 变为 22.9609 dB。
SSIM 由 0.776018 变为 0.778732。
LPIPS 由 0.339028 变为 0.332333。

官方局部

最终局部

参考局部

Sony 样例 2，图像 13

低光 RAW 预览

传统 ISP 示意

参考图

官方 Sony

最终 Sony

PSNR 由 29.9691 变为 31.2073 dB。
SSIM 由 0.860809 变为 0.861320。
LPIPS 由 0.242309 变为 0.241307。

官方局部

最终局部

参考局部

Sony 样例 3，图像 15

低光 RAW 预览

传统 ISP 示意

参考图

官方 Sony

最终 Sony

PSNR 由 18.7593 变为 19.5542 dB。
SSIM 由 0.802931 变为 0.808466。
LPIPS 由 0.383268 变为 0.377677。

官方局部

最终局部

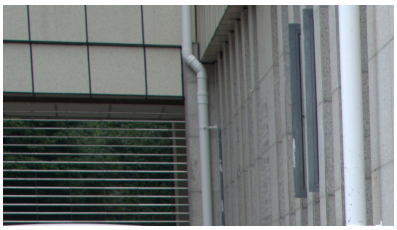

参考局部

Sony 样例 4，图像 22

低光 RAW 预览

传统 ISP 示意

参考图

官方 Sony

最终 Sony

PSNR 由 23.0287 变为 24.0857 dB。
SSIM 由 0.891086 变为 0.892855。
LPIPS 由 0.284596 变为 0.280901。

官方局部

最终局部

参考局部

Sony 样例 5，图像 29

低光 RAW 预览

传统 ISP 示意

参考图

官方 Sony

最终 Sony

PSNR 由 26.3440 变为 27.1834 dB。
SSIM 由 0.876454 变为 0.879337。
LPIPS 由 0.329056 变为 0.327271。

官方局部

最终局部

参考局部

Sony 样例 6，图像 41

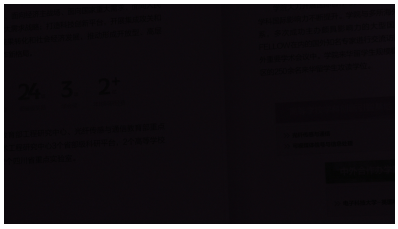

低光 RAW 预览

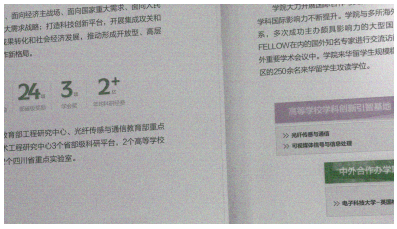

传统 ISP 示意

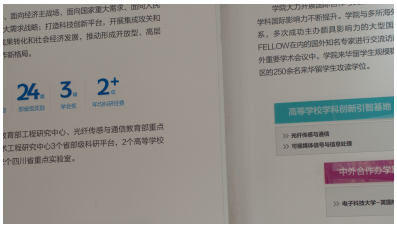

参考图

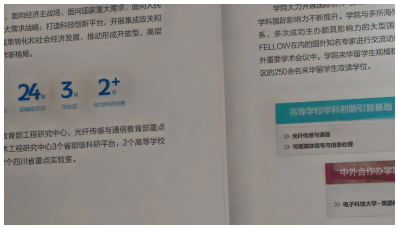

官方 Sony

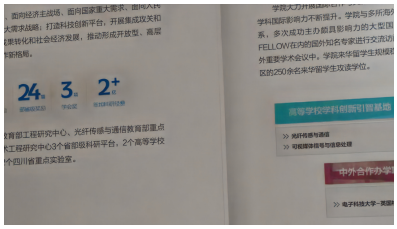

最终 Sony

PSNR 由 29.0547 变为 31.1765 dB。
SSIM 由 0.952606 变为 0.953630。
LPIPS 由 0.180129 变为 0.178401。

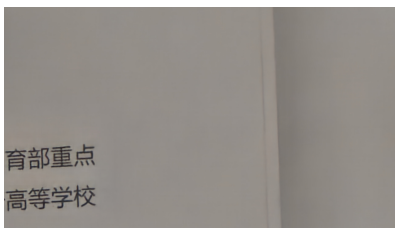

官方局部

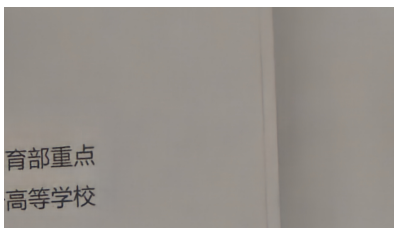

最终局部

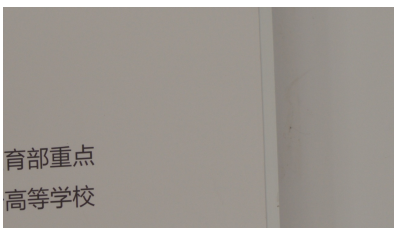

参考局部

3 图像增强实验总结

Canon 与 Sony 均完成各自全部 1000 张的增强和评价。两组实验分别使用对应相机的模型和固定划分。下表汇总最终结果，所有主指标均为逐图算术平均。

表 17 Canon 与 Sony 两个实验的最终结果

实验	图像数	PSNR / dB	SSIM	LPIPS
Canon	1000	26.707356	0.843515758	0.324355896
Sony	1000	26.721838	0.853275963	0.413931547

Canon 最终方案比冻结基线的平均 PSNR 提高 0.152867 dB，SSIM 略降。76 张留出测试的 PSNR 和 SSIM 也下降。效果图中同时保留了改善和下降样例，因此总体 PSNR 提高不能代替留出测试中的实际表现。

Sony 最终方案比同协议官方模型的平均 PSNR 提高 0.428325 dB，SSIM 提高 0.000891891，LPIPS 和各项颜色误差均改善。87 张留出测试的 PSNR 和 SSIM 也提高。GT-Mean 损失对照未达到预设门槛，最终采用已通过完整验证的 1000 步色彩表。

两组结果说明，小型色彩模型可以调整亮度和颜色，但实际收益仍要结合感知指标、颜色误差和留出测试判断。数据缓存、显存常驻和并行评分减少了部分等待，短测吞吐提高不代表完整训练具有相同加速比。

两个 1000 张总体都包含训练图及官方预训练已见的验证图。它们用于课程规定的全数据评价，不能写成 2000 张独立测试成绩。两个相机的数据与模型不同，报告保留各自结果，不合并成一个平均分。

第二部分 项目二几何校正

4 任务、数据和方法

课件提供 GeoCorrection 的 200 张照片和同名页面掩膜。任务是处理页面的倾斜、透视、弯曲和折痕，并用图像和有效指标评价校正效果。数据没有对应的平整参考图，也没有人工文字转录。

七类文件分别有普通拍摄 53 张、时间戳拍摄 82 张、曲面 7 张、折痕 4 张、透视 4 张、旋转 3 张和书页 47 张。逐文件路径、尺寸和哈希保存在`manifests/geocorrection/pairs.csv`。

4.1 传统页面校正

传统方法先根据页面掩膜寻找四角，再用单应性修正透视。随后分别沿列和沿行整理页面上下边与左右边。最后检测文本主方向，必要时旋转 90 度。长边限制为 1200 像素。该方法没有训练参数，但依赖输入掩膜的质量。

早期 200 张实验直接使用数据集的真值页面掩膜。它可以检查几何算法的能力，但不能代表无标注输入的自动处理效果。页面轮廓变直后，文字仍可能弯曲或被拉伸。

4.2 UVDoc 稠密展平和混合方法

UVDoc 根据照片预测反向网格，用于恢复页面内部的非线性形变 [7]。本项目使用公开预训练模型，输入为 712 乘 488，输出为 45 乘 31 网格，再对较高分辨率图像重映射。模型未在这 200 张图上继续训练。

该路线使用真值页面掩膜裁剪，边缘留量为 0.02。相同网格也作用于掩膜。混合方法在 UVDoc 结果上继续执行传统边界精修和方向校正。评价长边为 1200。UVDoc 和精修前后的图像均保留，用于观察页面外形和页内文字之间的取舍。

模型来自`PaddlePaddle/UVDoc_safetensors`，修订为

```
bfa6aad03b549c7e2cf89cefd2fb02ba3bef2ae4
```

权重 SHA256 为

```
65f980e3083b4919d962d7b4c8ddb42a926dc8b36f4909944746cf2d7b7325dc
```

历史环境为 PyTorch 2.8.0 加 CUDA 12.8 和 Transformers 5.19.0。模型获取地址为https://huggingface.co/PaddlePaddle/UVDoc_safetensors。

4.3 PageMaskUNet 自动页面分割

为了减少对真值掩膜的依赖，本项目训练 PageMaskUNet。它采用五层 U-Net，基础通道数为 32，使用 GroupNorm、SiLU、跳跃连接和双线性上采样。输入等比例缩放

并补边到 512 乘 512。模型输出单通道页面概率，阈值为 0.5。预测概率先恢复到原图大小，再生成二值掩膜。

训练按七类文件分层，种子为 20261018。训练、验证和测试数量分别为 156、22、22。损失由 0.35 倍 BCE、0.50 倍 Dice 损失和 0.15 倍相邻差分边界损失组成。使用 AdamW，批量大小 8，初始学习率为 3×10^{-4}，权重衰减为 10^{-4}。余弦调度最低学习率为初始值的 0.03，梯度范数限制为 1。训练使用 4090 和 BF16。

训练最多 100 轮。验证 IoU 连续 20 轮没有提高时停止，实际完成 92 轮。第 72 轮的验证 IoU 最高。划分清单、逐轮日志和测试摘要均保留。预测掩膜用于驱动原有传统校正，自动方法的几何测试长边为 1400。

自动方法采用预测掩膜和传统校正。200 张 UVDoc 实验采用真值掩膜辅助裁剪，两者分开评价。

5 几何与文字评价结果

5.1 页面分割

IoU 计算预测区域与真值区域的交并比。Dice 计算两区域交集的两倍除以面积和。Precision、Recall 及边界 F1 也同时记录。分割表使用训练程序的 512 像素评价设置。恢复到原图后再次测量的边界值可能不同，不应直接替换表中的历史测试值。

表 18 固定划分的页面分割结果

集合	IoU	Dice	Precision	Recall	边界 F1
验证 22 张	0.968092	0.983033	0.990334	0.977638	0.854937
测试 22 张	0.946106	0.969335	0.954000	0.991670	0.787976

测试损失为 0.04056449，验证损失为 0.02820705。区域 IoU 较高，但边界 F1 为 0.787976。阴影、弯曲和页面附近背景仍会影响边缘位置。高召回也可能伴随多保留背景。

5.2 22 张自动方法测试

边界 RMSE 和 P95 按图像尺度归一化，描述页面边缘对直线的偏离。填充率为页面掩膜占输出矩形的比例。文本倾斜由 Hough 文本边缘主方向估计。倾斜角和边界误差越低，表示对应诊断更好。

表 19 相同 22 张测试图的几何结果

指标	预测掩膜输入	预测掩膜输出	真值掩膜输入	真值掩膜输出
边界 RMSE	0.01885140	0.01352458	0.00796000	0.00040299
边界 P95	0.03911691	0.03192278	0.01966474	0.00021211
页面填充率	0.411242	0.982870	0.398952	0.999790
文本倾斜 / 度	9.993837	7.103551	10.064026	6.096917

预测掩膜驱动的校正将平均文本倾斜由 9.993837 度降至 7.103551 度。平均校正时间为 3026.379731 毫秒，不含独立页面分割的全部开销。相同图像使用真值掩膜时，平均倾斜为 6.096917 度，平均校正时间为 2991.105506 毫秒。

两种设置的输入边界由不同掩膜测得。只能在各自设置内部比较输入和输出。预测掩膜的边缘误差会进入后续变换，因此与真值掩膜结果仍有明显差距。

5.3 200 张真值掩膜辅助实验

表 20 200 张历史几何实验

设置	边界 RMSE	边界 P95	填充率	倾斜 / 度
传统输入	0.00835700	0.02042421	0.412613	8.303751
传统校正	0.00036439	0.00023126	0.999773	5.845216
UVDoc 裁剪输入	0.01183585	0.02888562	0.755385	7.597270
UVDoc 输出	0.00540183	0.01223654	0.977840	5.327889
混合输出	0.00071432	0.00011874	0.999848	5.113268

传统方法与 UVDoc 使用不同的页面裁剪，因此两行输入指标不同。混合精修又有一次重采样和方向预处理，其程序内输入倾斜为 5.437830 度。表中分别保留原摘要值，没有将不同输入阶段写成完全一致的评价对象。

UVDoc 的平均模型前向为 4.816419 毫秒，高分辨率重映射及后处理为 1546.422740 毫秒，完整 UVDoc 处理为 2372.902562 毫秒。混合精修再增加 1718.833591 毫秒。CPU 重映射和后处理占用较多时间，单独加快网络前向的收益有限。

混合方法的外边界更规整，但部分曲面和折痕的文本倾斜变差。接近 1 的填充率只说明页面几乎铺满矩形，不能证明文字完全恢复。

5.4 固定 40 张 OCR 诊断

按七类文件固定抽取 40 张，使用相同 PP-OCRv6 medium 检测和识别模型。历史环境为 PaddleOCR 3.7.0、PaddleX 3.7.2 和 Transformers 5.19.0。长边为 1200，置信度阈值为 0.8。

表 21 40 张 OCR 可读性诊断

方法	文本行	高置信行	高置信字符	平均置信度	加权字符
输入	2,679	2,171	35,226	0.891321	36356.93
传统	2,292	1,530	24,860	0.828621	28945.42
UVDoc	2,966	2,541	42,689	0.913456	43765.28
混合	2,937	2,476	42,987	0.906133	43911.12

混合方法的高置信字符数比输入增加 22.03%。33 张增加、1 张持平、6 张减少。UVDoc 的平均行置信度较高，混合方法的字符总量较高。传统校正的高置信字符反而减少，说明边界变直不能代替文字内容检查。

数据没有人工转录，因此这些数值不能写成识别准确率、CER 或 WER。没有平整参考图，也不能把输入与校正图的 PSNR 或 SSIM 写成几何恢复质量。

6 几何校正对比图

下列 7 组四列图来自 200 张历史真值掩膜辅助实验，包含书页、拍摄、曲面、折痕、透视和旋转。最后一组来自自动方法的隔离测试。所有图均从已保存的对比图按原位置截取，未重新生成结果。

几何样例 1，150

页面裁剪

传统校正

UVDoc

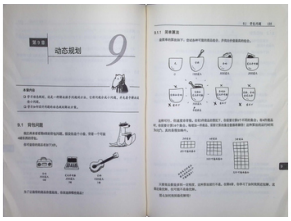
UVDoc 后精修

几何样例 2，20260401_103937

页面裁剪

传统校正

UVDoc

UVDoc 后精修

几何样例 3，IMG_20260326_105848

页面裁剪

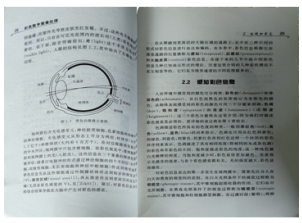
传统校正

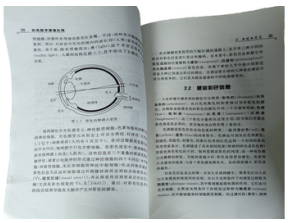
UVDoc

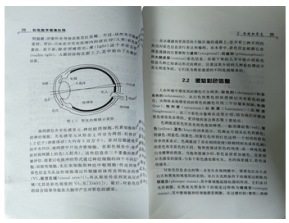
UVDoc 后精修

几何样例 4，dewarp20260728_curved_029

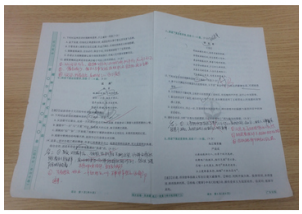
页面裁剪

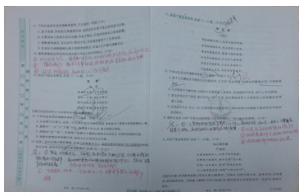
传统校正

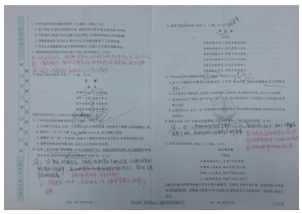
UVDoc

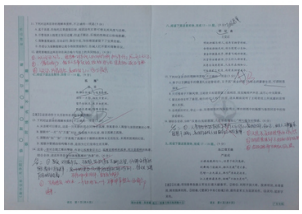
UVDoc 后精修

几何样例 5，dewarp20260728_fold_020

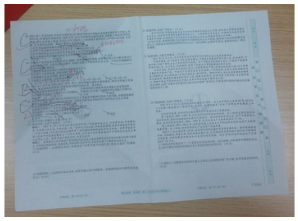
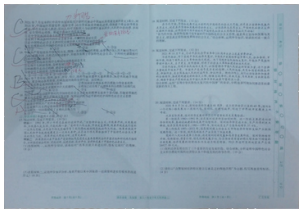
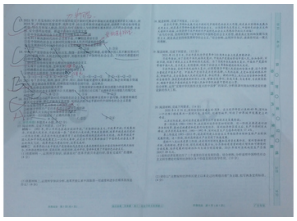
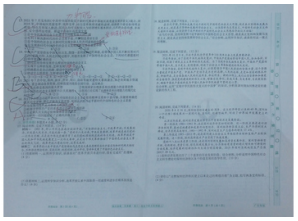

页面裁剪　　传统校正　　UVDoc　　UVDoc 后精修

几何样例 6，dewarp20260728_perspective_019

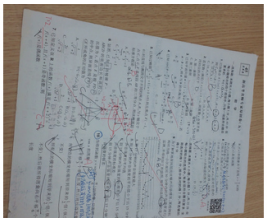

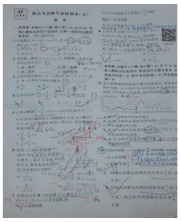
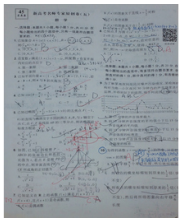

页面裁剪　　传统校正　　UVDoc　　UVDoc 后精修

几何样例 7，dewarp20260728_rotate_018

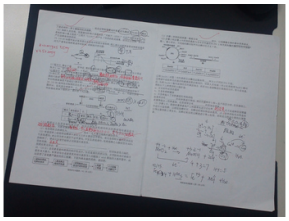

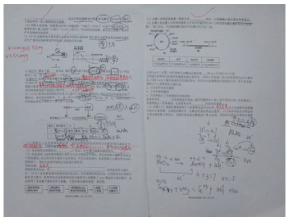
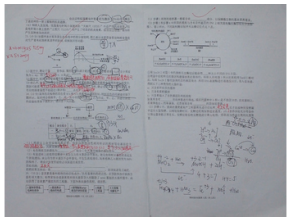

页面裁剪　　传统校正　　UVDoc　　UVDoc 后精修

自动校正测试样例

原图、预测掩膜、单应性和边界校正依次列出。图像编号为 dewarp20260728_perspective_019。

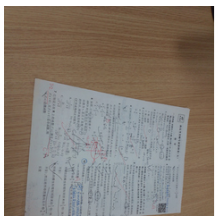

原始图像　　预测掩膜　　单应性　　边界校正

该图来自 22 张隔离测试。其掩膜由 PageMaskUNet 预测。页面外边界更规整，页内形变仍有残留。

7 几何校正复现入口

主要入口如下。环境安装、固定 22 张测试清单和完整命令见附件完整复现命令.txt。

```
dip-train-page-segmentation
dip-infer-page-segmentation
dip-rectify-classical
dip-infer-uvdoc
```

原始数据应包含images/ 与mask/ 各 200 张。先核对清单，再运行分割和几何校正。旧分割权重的记录 SHA256 如下，当前原数据和该权重未随包提供，重新生成结果需要补齐。

```
250789695f3c92b3acaa2c373fb6a51083cf0dfa54093ed3acd3c2cd084eccc6
```

现有训练代码、划分、日志和逐图指标保留。UVDoc 模型及 OCR 文件哈希按原公开来源和reports/assets/geocorrection/ocr/model_sha256.txt 核对。后续可改善分割边缘，再检验预测掩膜与 UVDoc 组合的效果。

第三部分 项目三图像压缩

8 数据、编码方法和评价口径

Kodak 共有 24 张 8 位 RGB PNG。18 张为 768 乘 512，6 张为 512 乘 768。每张均有 393216 个像素。原 PNG 总大小为 15,394,305 字节，未压缩 RGB 总量为 28,311,552 字节。

数据固定到 Kodak 仓库提交 `dd2e1105fe8d9afe1120cd7e4c0e5e41f509a81b`。逐文件 SHA256 见`manifests/compression/kodak.sha256`。传统与学习式程序的聚合哈希组织不同，复现时按逐文件清单核对。

8.1 四种已经执行的方法

JPEG 基线通过 Pillow 调用 libjpeg，使用 4:2:0 色度抽样，质量档为 30、50、70 和 90。质量因子 Q 用于控制量化强度。Q 本身不表示 PSNR，也不表示固定压缩比。不同模型的 Q 不是相同的数值尺度。

自研 DCTC 先将 RGB 变为 YCbCr，再进行 4:2:0 抽样、8 乘 8 正交 DCT、质量缩放量化、Zigzag 和 DC 差分。v1 使用 AC 零游程和 zlib DEFLATE。v2 采用向量化处理，删除末尾零系数，再打包 int16 系数并使用较快的 zlib 级别。两个版本都有独立的码流和解码程序，不依赖原图完成解码。

Cheng2020 Anchor 使用 CompressAI 1.2.8 公开 MSE 预训练模型 [8, 9]。测试 Q1、Q3 和 Q6。模型使用神经网络变换、超先验和自回归上下文来编码潜变量。Kodak 只用于本项目测试，没有用于模型再训练。报告没有把 Anchor 版本写成额外执行过的 Attention 版本。

8.2 压缩比和码率公式

设全部图像的实际编码字节之和为 B，总像素数为 P，则

$$\mathrm{bpp} = \frac{8B}{P}, \qquad R_{\mathrm{RGB}} = \frac{3P}{B}, \qquad R_{\mathrm{PNG}} = \frac{15394305}{B}. \tag{6}$$

原始 RGB 空间节省率为 $100(1 - B/(3P))$。压缩比越大，体积越小。表中的压缩比均为全部文件总字节相除，没有平均各图的比值。因为 24 张像素数相同，本实验的平均逐图 bpp 也等于总码率。

JPEG 与 DCTC 统计实际文件字节，包括各自码流头。Cheng 历史程序统计 `compress` 返回的实际熵编码字符串，包含主潜变量和超先验负载，没有统计独立文件容器头，也没有统计共享模型权重。因此，Cheng 表中结果应称为熵码流负载压缩比，不能声称已经包含完整自描述文件的全部开销。

质量指标在解码 RGB 与原图之间计算，范围为 0 到 1。每个档位的 PSNR 和 SSIM 均为 24 张逐图指标的算术平均。未用估计熵代替实际压缩字节。

9 完整 24 张的压缩结果

表 22 全部质量档的码率、质量和时间

方法	Q	bpp	PSNR / dB	SSIM	编码 / ms	解码 / ms
JPEG	30	0.659793	30.491473	0.86510658	0.5150	0.4991
JPEG	50	0.905521	32.173816	0.89965099	0.5461	0.5828
JPEG	70	1.238758	33.916748	0.92590776	0.5867	0.6814
JPEG	90	2.346323	38.033973	0.96335302	0.7168	0.9593
DCTC v1	30	0.711529	30.368194	0.86146591	42.4472	37.9828
DCTC v1	50	1.031225	32.027475	0.89682716	54.1809	50.7860
DCTC v1	70	1.455683	33.740348	0.92367104	68.1909	66.8513
DCTC v1	90	2.828743	37.676940	0.96201487	106.2965	116.5575
DCTC v2	30	0.995764	30.368194	0.86146591	7.1717	4.3162
DCTC v2	50	1.405468	32.027475	0.89682716	7.4865	4.3906
DCTC v2	70	1.944790	33.740348	0.92367104	7.9520	4.5039
DCTC v2	90	3.607437	37.676940	0.96201487	9.2594	4.7574
Cheng-A	1	0.119554	28.580356	0.76545180	2455.3542	6525.7653
Cheng-A	3	0.270888	31.340510	0.85727013	2225.8119	5775.7768
Cheng-A	6	0.805637	36.704702	0.94686304	2249.0610	5784.8805

表 23 全部质量档的两种压缩比和空间节省率

方法	Q	码流字节	RGB 压缩比	PNG 压缩比	RGB 节省 / %
JPEG	30	778,323	36.375068	19.778813	97.2509
JPEG	50	1,068,196	26.504080	14.411498	96.2270
JPEG	70	1,461,298	19.374249	10.534679	94.8385
JPEG	90	2,767,835	10.228772	5.561858	90.2237
DCTC v1	30	839,354	33.730169	18.340658	97.0353
DCTC v1	50	1,216,482	23.273301	12.654774	95.7032
DCTC v1	70	1,717,193	16.487111	8.964808	93.9347
DCTC v1	90	3,336,921	8.484334	4.613326	88.2136
DCTC v2	30	1,174,651	24.102097	13.105429	95.8510
DCTC v2	50	1,657,958	17.076158	9.285100	94.1439
DCTC v2	70	2,294,168	12.340662	6.710191	91.8967
DCTC v2	90	4,255,506	6.652923	3.617503	84.9690
Cheng-A	1	141,032	200.745590	109.154695	99.5019
Cheng-A	3	319,552	88.597637	48.174648	98.8713
Cheng-A	6	950,368	29.790094	16.198257	96.6432

Cheng-A Q6 的熵码流总量为 950368 字节，原始 RGB 压缩比为 29.790094，PNG 文件压缩比为 16.198257。平均 PSNR 为 36.704702 dB，SSIM 为 0.94686304。Q1 体积更小，但 PSNR 和 SSIM 也更低。

JPEG Q70 为 1.238758 bpp 和 33.916748 dB。Cheng Q6 在更低码率下得到更高的 PSNR 和 SSIM。两者的计时平台和容器开销不同，所以质量优势与部署速度分别解释，不合成单一性能分数。

DCTC v1 和 v2 的重建质量相同，但码流大小和时间不同。在 Q70，v2 编码为 7.952045 毫秒，解码为 4.503950 毫秒。v1 编码为 68.190934 毫秒，解码为 66.851325 毫秒。v2 更快，但原始 RGB 压缩比由 16.487 降至 12.341。自研实现仍未超过成熟 libjpeg 的综合表现。

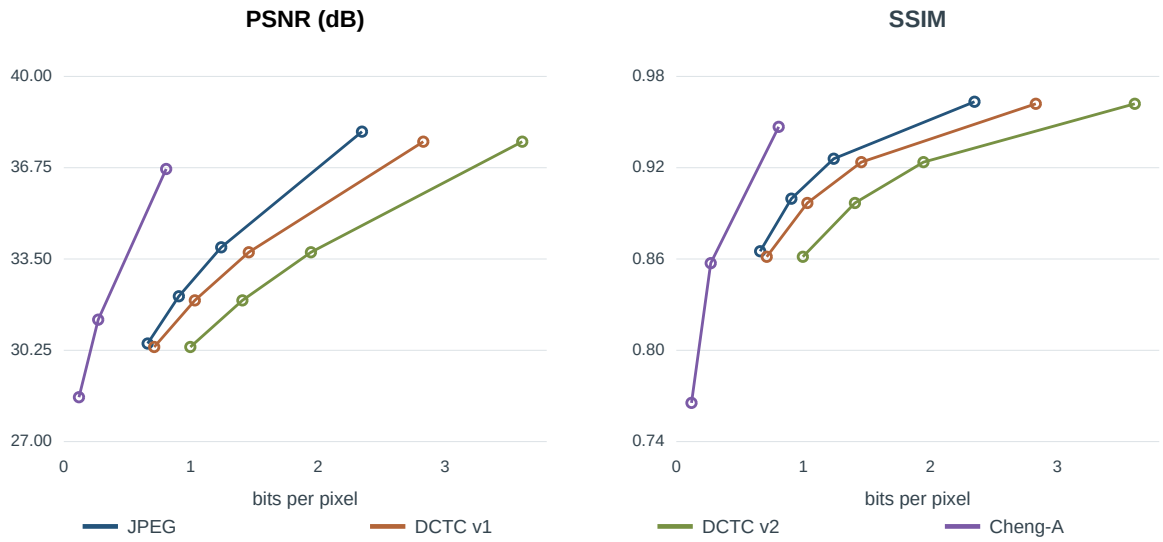

图 2 四种方法的实际率失真工作点。横轴为 bpp，左图为 PSNR，右图为 SSIM。曲线连接已测档位，不代表连续码率已经验证。Cheng 的横轴为熵码流负载口径。

JPEG 计时先预热 2 次，再执行 7 次，每图取中位数。DCTC 预热 1 次，重复 3 次。传统实验环境记录为 Python 3.12.14、NumPy 2.5.3 和 Pillow 12.3.0。学习模型使用 4090、Python 3.12.3 和 PyTorch 2.8.0 加 CUDA 12.8，预热 0 次、重复 1 次。

表中 Cheng 的编码约 2.2 秒，解码约 5.8 秒。其自回归熵处理较慢。传统计时不含质量指标和写盘，学习模型计时为实际压缩与解压调用。硬件与重复次数不同，因此这些是各自环境的历史耗时，未当作严格相同硬件的加速比。

10 压缩重建对比图

以下选择历史固定样例 01、04、13、23 和 24。每组列出原图、三个 Cheng 档位和传统方法的代表档位。图像从封存对比图中截取，没有运行新压缩，也没有人为锐化。展示分辨率低于原始图，细微块效应应结合原生解码图检查。

Kodak 样例 01

原图

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

Kodak 样例 04

原图

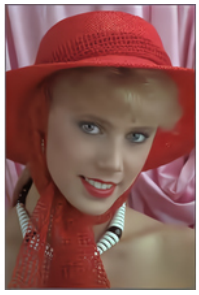

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

Kodak 样例 13

原图

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

Kodak 样例 23

原图

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

Kodak 样例 24

原图

Cheng Q1

Cheng Q3

JPEG Q70

DCTC v1 Q70

DCTC v2 Q70

Cheng Q6

JPEG Q90

DCTC v1 Q90

11 压缩项目复现入口

JPEG 与 DCTC 不需要训练权重。自研编码器位于`src/dip_course/compression/dct_codec.py`。三个评价入口如下。

```
dip-compress-benchmark
dip-dct-benchmark
dip-learned-compression-benchmark
```

JPEG 使用 Q30、Q50、Q70、Q90 和 4:2:0 抽样。DCTC v1 使用 `stream-format=rle`、`entropy-level=9`，v2 使用 `trimmed` 和级别 1。Cheng-A 采用 CompressAI 1.2.8 官方 MSE 预训练模型，Q1、Q3、Q6。原实验未保存三个公开模型的完整 SHA256，复现时应记录实际下载文件。

完整下载、审计与四种方法的命令见完整复现命令.txt。JPEG 和 DCTC 各生成 96 次编码评价，Cheng 生成 72 次。不同方法和复现批次应写入不同目录。后续优先统一硬件、容器开销和计时方式，再比较相同码率下的质量。

第四部分 提交与复核

12 提交材料与使用说明

https://github.com/xuntonghan/digital-image-proocess-work

https://github.com/xuntonghan/digital-image-proocess-work/releases

仓库为私有，阅卷者需要访问权限。PDF、LaTeX 工程和代码位于仓库，提交包及自训增强权重位于 Releases。

表 24 提交附件

附件	内容
综合 PDF 和 LaTeX 工程	三项方法、参数、指标、31 组对比图与参考资料
代码与指标包	固定源码、数据划分、逐图 CSV、训练日志和复现入口
自训增强权重包	Canon 原 5 份权重、Sony 最终色彩表和两个未采用对照，共 8 份，附 SHA256 核验脚本
完整复现命令	安装、数据审计、模型推理和压缩评价的逐步操作

重新推理需要相应原始数据和模型。增强总体含训练图，几何指标不代表 OCR 准确率，学习式压缩码率不含共享模型。上述口径与各项目表格一致。

课程提交文件为韩勋同-2025312132086-数字图像处理课程实习.zip。

参考文献

[1] Hai Jiang, Binhao Guan, Zhen Liu, et al. Learning to See in the Extremely Dark. ICCV, 2025, 7676–7685. https://github.com/JianghaiSCU/SIED.

[2] Liangyu Chen, Xiaojie Chu, Xiangyu Zhang, Jian Sun. Simple Baselines for Image Restoration. ECCV, 2022. https://arxiv.org/abs/2204.04676.

[3] Xiaojie Chu, Liangyu Chen, Chengpeng Chen, Xin Lu. Improving Image Restoration by Revisiting Global Information Aggregation. ECCV, 2022. https://arxiv.org/abs/2112.04491.

[4] Hui Zeng, Jianrui Cai, Lida Li, Zisheng Cao, Lei Zhang. Learning Image-adaptive 3D Lookup Tables for High Performance Photo Enhancement in Real-time. IEEE TPAMI. https://doi.org/10.1109/TPAMI.2020.3026740.

[5] Wontae Kim, Keuntek Lee, Nam Ik Cho. Lightweight and Fast Real-time Image Enhancement via Decomposition of the Spatial-aware Lookup Tables. ICCV, 2025, 11895–11905. https://github.com/WontaeaeKim/SVDLUT.

[6] Jingxi Liao, Shijie Hao, Richang Hong, Meng Wang. GT-Mean Loss: A Simple Yet Effective Solution for Brightness Mismatch in Low-Light Image Enhancement. ICCV, 2025, 6112–6121. https://github.com/jingxiLiao/GT-mean-loss.

[7] Floor Verhoeven, Tanguy Magne, Olga Sorkine-Hornung. UVDoc: Neural Grid-based Document Unwarping. SIGGRAPH Asia, 2023. https://tanguymagne.com/publications/uvdoc/.

[8] Zhengxue Cheng, Heming Sun, Masaru Takeuchi, Jiro Katto. Learned Image Compression With Discretized Gaussian Mixture Likelihoods and Attention Modules. CVPR, 2020, 7939–7948. https://github.com/InterDigitalInc/CompressAI.

[9] CompressAI 预训练模型接口与官方实现。https://interdigitalinc.github.io/CompressAI/zoo.html.

[10] 数字图像处理课程课间实习课件，武汉大学，2026 年 9 月 30 日，第 8、9、14 页。